



中国研究生创新实践系列大赛
中国光谷·“华为杯”第十九届中国研究生
数学建模竞赛

学 校 浙江大学

参赛队号 22103350038

队员姓名	1.	张森
	2.	李昂
	3.	李宝奎

中国光谷·“华为杯”第十九届中国研究生 数学建模竞赛

题 目 草原放牧策略研究

摘 要：

草原在维护生物多样性、涵养水土等方面具有重要的生态功能，自我国实施“退牧还草”政策以来，在保护和改善草原生态环境、改善民生方面取得了显著成效。合理的放牧政策是带动区域经济、防止草原沙漠化及保障民生的关键，放牧优化问题的研究也为国家、政府制定放牧政策和草原管理决策提供科学的依据。本文通过构建土壤物理和化学性质机理模型、最大放牧羊群优化模型等一系列相关模型，给出科学合理的放牧策略，保证草原的可持续发展。具体做法如下：

针对问题 1，为了建立不同放牧策略对锡林郭勒草原土壤物理性质（土壤湿度）和植被生物量影响的数学模型，首先对影响土壤湿度变化和植被生长速度变化的因素进行机理分析，得到降水和蒸发等自然条件与放牧方式和放牧强度等放牧策略是影响两者的机理因素。根据以上影响因素对 Woodward 等人建立的放牧与植物生长模型和土壤含水量-降水量-地表蒸发模型进行改进得到植被生物量演变模型和土壤物理性质演变模型。最后整合原始数据与搜集的数据设计实验，验证所得的模型的具有高准确性以及强鲁棒性。

针对问题 2，题目要求根据土壤湿度、土壤蒸发和降水等数据建立模型预测保持目前放牧策略不变情况下的 2022 年、2023 年不同深度土壤湿度。首先合并与土壤湿度相关的特征数据集，通过分步特征过滤与随机森林筛选重要特征，并使用特征相关性分析进一步对特征类内与类间的冗余特征过滤，最终得到降水量、土壤蒸发量、平均能见度和径流量共 4 个重要特征，并对选出的特征进行独立性和代表性检验。为了保证模型的准确性，选用能捕捉时间序列关系的强性能 LSTM-FC 模型分别对每个月份的土壤湿度预测建模得到 12 个模型，以降水量、土壤蒸发量等特征作为模型的输入，预测未来两年不同深度的土壤湿度。最后使用基于 Stacking 的集成学习模型作为对比，验证了构建的 LSTM-FC 模型效果更好。

针对问题 3，首先通过机理分析，确定影响土壤有机碳的因素有植被数量、植被自然枯萎转化等，影响土壤无机碳的因素为植被数量，影响土壤全氮的因素为土壤中的有机物质，根据以上因素结合问题 1 得到的两个演变模型得到土壤有机碳、无机碳和全氮机理模型。

基于数据量和模型简单通用的特点,建立简单高效的 **GRU-FC 模型**预测监测样地在不同放牧强度下 2022 年土壤同期有机碳、无机碳、全氮的含量。

针对问题 4,首先通过查阅资料得到了影响沙漠化指数的各因素,选取气候因素(风速、气温和降水量)、地表因素(植被覆盖度和土壤湿度)和人文因素(畜牧数、人均家庭收入),利用**层次分析法**获取影响因子权重,根据预测数据和真实数据修正模型参数,得到**沙漠化程度指数预测模型**,最后进行模型参数检验。其次,根据题意得知影响土壤板结化程度的主要因素为土壤湿度、容重和有机物含量,分别由参考文献得到容重数据、由问题一土壤湿度机理模型得到土壤湿度数据、由问题三土壤化学性质机理模型得到有机物含量数据,使用**熵权法**得到影响因子权重并检验,进而得到监测点的**土壤板结化程度模型**。最后,结合以上两个模型,带入不同放牧策略下的相关数据,得到相应的沙漠化指数和土壤板结化程度,通过最小化两者的加权和并进行合理性分析,得知应选取**轻牧**的放牧策略。

针对问题 5,根据可持续发展的定义,一方面**生物环境承载能力**可使用问题四中的沙漠化程度和板结化程度衡量,当两者达到阈值即为达到该地的生物环境承载能力。另一方面,经济规模可使用草场内牧羊的数量衡量,牧羊的数量越大,其**经济规模**越大。因此,要保证可持续发展即为提高牧羊的数量的同时保证不超出本地的沙漠化程度和板结化程度阈值,建立了**最大放牧羊群优化模型**,将最大化牧羊的数量作为优化目标,选取问题 4 中的 9 个环境因子作为模型的**决策变量**,通过查阅资料确定决策变量的取值范围,并以土壤沙漠化程度与土壤板结化程度为约束。由于搜索空间较大,因此采用一种广泛用于优化问题的粒子群算法对该模型进行求解,并针对算法中的**惯性因子**等参数进行改进得到搜索能力更强、精度更高的**基于分子运动论的遗传粒子群优化算法 GA-MPSO**,使得算法与问题的契合度更高。然后对上述线性规划模型进行求解,得到降水量为 300mm、600mm、900mm 和 1200mm 情形下的最大放牧羊的数量分别为 3.91、4.56、6.03、7.12。最后,将 GA-MPSO 算法与改进前的优化算法进行对比,验证了改进后的算法具有避免过早收敛、提升搜索精度的优点。

针对问题 6,从示范牧户信息中获取三种放牧策略,这三种策略涵盖了问题四得到的最优放牧策略(轻牧),因此演示这三种放牧策略对于土地状态影响。对于土壤肥力变化,利用放牧策略和初始生物量干重之和和相似度,得到牧户和放牧小区的匹配关系,将放牧小区初始土地化学性质特征带入问题三的土壤化学性质模型得到预测结果;对于土壤湿度,利用 **ARIMA 时间序列**分别建立降雨量和蒸发量预测模型,将未来降雨量、蒸发量和放牧策略带入问题一的**土壤湿度机理模型**得到预测结果;对于植被覆盖,将牧户放牧策略和初始生物量之和带入问题一的**植被生物量机理模型**得到预测结果。比较三种放牧策略下的土壤肥力变化、土壤湿度和植被覆盖的预测结果,轻牧策略下土壤状态最好,验证了问题 4 准确性。

关键词: 演变模型, LSTM-FC 模型, 熵权法, 基于分子运动论的遗传粒子群优化算法 GA-MPSO, ARIMA 时间序列

目 录

一、 问题重述	9
1.1 问题背景	9
1.2 问题的提出	10
二、 总体技术路线图	11
三、 基本假设与符号说明	12
3.1 基本假设	12
3.2 符号说明	12
四、 问题一的求解：放牧自然演变模型	13
4.1 问题分析	13
4.2 模型建立	15
4.2.1 机理分析	15
4.2.2 植被生物量演变模型	15
4.2.3 土壤湿度演变模型	16
4.2.4 基于植被指数（NDVI）的植被地上生物量模型	17
4.3 模型求解与检验	17
4.3.1 植被生物量演变模型求解与检验	17
4.3.2 土壤湿度演变模型求解与检验	19
五、 问题二的求解：LSTM 未来序列预测模型	21
5.1 问题分析	21
5.2 数据分析与预处理	23
5.2.1 缺失值与异常值检测	23
5.2.2 重复特征过滤	23
5.3 基于随机森林的综合重要特征筛选	24
5.3.1 随机森林训练	24
5.3.2 特征重要性计算	24
5.3.3 强相关性特征过滤	27
5.3.4 特征独立性与代表性检验	28
5.4 建型的建立与求解	30
5.4.1 数据分布观察与可视化	30
5.4.2 基于数据驱动模型调研	33
5.4.3 长短期记忆网络（LSTM）介绍	33
5.4.4 基于 LSTM-FC 网络的土壤湿度预测模型	34
5.4.5 其他模型的预测方法	35
5.4.6 评价指标	36
5.4.7 模型结果分析	37
5.4.8 模型对 2022、2023 年预测结果	40
六、 问题三的求解：土壤化学性质机理模型	41
6.1 问题分析	41
6.2 土壤化学性质机理模型的建立	42
6.3 土壤化学性质机理模型的求解	45
6.3.1 数据分布观察与可视化	45

6.3.2 门控循环神经网络（GRU）介绍	45
6.3.3 基于 GRU-FC 网络的土壤化学性质预测模型	46
6.3.4 模型结果分析	47
6.3.5 模型对 2022 年土壤化学性质预测结果	49
七、 问题四的求解：放牧策略模型	49
7.1 问题分析	49
7.2 沙漠化程度指数预测模型的建立	50
7.2.1 沙漠化程度指数预测模型分析	50
7.2.2 获取因子强度集合	51
7.3 沙漠化程度指数预测模型的求解与检验	52
7.3.1 因子权重的计算	52
7.3.2 模型参数修正	56
7.3.3 模型准确性验证	57
7.4 土壤板结化模型的建立	57
7.4.1 土壤板结化定义	57
7.4.2 土壤板结化指标评价模型	57
7.5 土壤板结化模型的求解与检验	58
7.6 放牧策略模型的建立与求解	60
八、 问题五的求解：最大放牧羊群优化模型	60
8.1 问题分析	60
8.2 最大放牧羊群线性规划模型建立	62
8.3 模型求解	63
8.3.1 粒子群算法（PSO）	63
8.3.2 基于分子运动论的粒子群优化算法（MPSO）	64
8.3.3 基于分子运动论的遗传粒子群优化算法（GA-MPSO）	66
8.3.4 模型参数设定	67
8.3.5 结果分析与可视化	67
8.4 模型对比	69
九、 问题六的求解：牧户土地状态预测及演示	69
9.1 问题分析	69
9.2 牧户地理位置分析	71
9.3 牧户与放牧小区的匹配	71
9.3.1 牧户放牧强度匹配	71
9.3.2 牧户样方生物量干重之和匹配	72
9.4 牧户土壤肥力变化预测	73
9.4.1 土壤肥力变化预测分析	73
9.4.2 土壤肥力变化趋势预测	73
9.4.3 土壤肥力变化预测结果	75
9.5 牧户土壤湿度预测	75
9.5.1 土壤湿度预测分析	75
9.5.2 ARIMA 时间序列预测模型	76
9.5.3 ARIMA 模型预测降雨量特征	76
9.5.4 ARIMA 模型预测蒸发量特征	78
9.5.6 土壤湿度模型预测变化趋势	80

9.5.7 土壤湿度模型预测结果展示	81
9.6 牧户植被覆盖程度预测	81
9.6.1 植被覆盖程度预测分析	81
9.6.2 植被覆盖程度趋势预测	81
9.5.7 植被覆盖程度模型预测结果展示	82
十、 模型评价与改进	83
10.1 模型优点	83
10.2 模型缺点	83
10.3 模型的改进与推广	84
参考文献	84
附录	85

公众号：竞赛资料网

图 录

图 1 全文技术路线图	11
图 2 放牧过程的连续演变过程	13
图 3 问题一思路流程图	14
图 4 植被生物量变化预测对比图	18
图 5 植被生物量变化预测对比	19
图 6 土壤湿度预测对比	20
图 7 土壤湿度与变量波动幅度敏感性分析	21
图 8 问题二的思路流程图	22
图 9 不同阈值删除特征数图	23
图 10 随机森林训练过程流程图	25
图 11 土壤 10cm 湿度重要特征分析图	26
图 12 土壤 40cm 湿度重要特征分析图	26
图 13 土壤 100cm 湿度重要特征分析图	26
图 14 土壤 200cm 湿度重要特征分析图	27
图 15 特征相关性热力图	28
图 16 4 个变量的相关性热图	29
图 17 变量筛选及其权重展示图	30
图 18 不同湿度和四个特征的分布范围图	31
图 19 土壤不同湿度和四个特征随时间连续变化图	31
图 20 土壤不同湿度和四个特征不同月按年变化图	32
图 21 LSTM 结构图	33
图 22 土壤湿度预测模型汇总图	34
图 23 LSTM-FC 结构图	35
图 24 土地湿度 10cm 的四个月份预测结果比较图	37
图 25 土地湿度 40cm 的四个月份预测结果比较图	38
图 26 土地湿度 100cm 的四个月份预测结果比较图	38
图 27 土地湿度 200cm 的四个月份预测结果比较图	39
图 28 Stacking 模型和 LSTM-FC 模型拟合结果汇总比较图	39
图 29 问题三的思路流程图	42
图 30 土壤化学性质数据观测图	45
图 31 GRU 模型结构图	45
图 32 土壤化学性质预测模型汇总图	46
图 33 GRU-FC 模型结构图	47
图 34 NG-G17 的五个土壤化学性质特征预测结果比较图	47
图 35 LGI-G6 的五个土壤化学性质特征预测结果比较图	48
图 36 MGI-G8 的五个土壤化学性质特征预测结果比较图	48
图 37 HGI-G9 的五个土壤化学性质特征预测结果比较图	48
图 38 问题四思路流程图	50
图 39 沙漠化程度影响指标体系图	51
图 40 B 层三个指标权重展示图	54
图 41 B 气候因子指标权重展示图	55

图 42 (115.375, 44.125) 坐标位置图	56
图 43 问题五的思路流程图	61
图 44 粒子群优化算法流程图	64
图 45 粒子群演化过程图	67
图 46 适应度进化曲线图	68
图 47 适应度进化曲线对比图	69
图 48 问题六的思路流程图	70
图 49 地理位置示意图	71
图 50 牧户一与中牧放牧小区植物干重之和对比图	72
图 51 牧户二与轻牧放牧小区植物干重之和对比图	73
图 52 牧户三与重牧放牧小区植物干重之和对比图	73
图 53 牧户一土壤肥力变化趋势观测图	74
图 54 牧户二土壤肥力变化趋势观测图	74
图 55 牧户三土壤肥力变化趋势观测图	75
图 56 降雨量预测模型 ACF 检验结果图	77
图 57 降雨量预测模型 PACF 检验结果图	77
图 58 降雨量预测模型拟合和预测结果图	78
图 59 蒸发量预测模型 ACF 验证图	79
图 60 蒸发量预测模型 PACF 验证图	79
图 61 蒸发量预测模型拟合效果和预测结果图	80
图 62 三个牧户土壤湿度预测图	80
图 63 牧户植被覆盖程度变化趋势图	82

表 录

表 1 植被指数 NDVI 与植被地上生物量的回归模型	17
表 2 模型改进前后性能对比	17
表 3 模型损失对比	18
表 4 模型改进前后性能对比	20
表 5 敏感性分析结果	20
表 6 四个特征信息熵权重及其累计值	30
表 7 回归分析方法比较	32
表 8 训练集、测试集的维度	35
表 9 模型指标结果比较表	40
表 10 预测结果汇总表	40
表 11 模型指标结果比较表	48
表 12 土壤化学性质预测结果汇总表	49
表 13 指标因子上下界限表	52
表 14 模型参数权重合成表	56
表 15 国际沙漠划分程度分数表	56
表 16 参数修正前后表	57
表 17 不同条件下土壤容重统计特征值表	59
表 18 监测区域不同放牧强度下的土壤板结化程度分数表	59
表 19 土壤板结化程度划分分数表	60
表 20 监测区域不同放牧强度下的沙漠化程度与土壤板结化程度分数之和表	60
表 21 MPSO 算法与分子运动论的相似关系表	65
表 22 基于分子运动论的遗传粒子群优化算法参数设置表	67
表 23 各降水量样本收敛时迭代次数和最优解表	68
表 24 样本优化后的环境条件表	69
表 25 牧户放牧强度表	72
表 26 土壤肥力特征预测结果表	75
表 27 降雨量 ADF 检验表	77
表 28 蒸发量 ADF 检验表	78
表 29 不同放牧强度土壤湿度预测结果	81
表 30 植被覆盖程度预测结果表	82

一、问题重述

1.1 问题背景

草原作为世界上分布最广的重要的陆地植被类型之一，分布面积广泛。中国的草原面积为 3.55 亿公顷，是世界草原总面积的 6%~8%，居世界第二。此外，草原在维护生物多样性、涵养水土、净化空气、固碳、调节水土流失和沙尘暴等方面具有重要的生态功能。自 2003 年党中央、国务院实施“退牧还草”政策以来，在保护和改善草原生态环境、改善民生方面取得了显著成效。“退牧还草”并不是禁止放牧，除了部分区域禁牧外，很多草原实行划区轮牧以及生长季休牧。合理的放牧政策是带动区域经济、防止草原沙漠化及保障民生的关键，放牧优化问题的研究也为国家、政府制定放牧政策和草原管理决策提供科学的依据。

关于草原放牧通常要考虑放牧方式和放牧强度（单位面积牲畜密度）2 个因素。放牧方式可以分为多种，有文献将放牧方式分为以下五种，分别为：全年连续放牧、禁牧、选择划区轮牧、轻度放牧、生长季休牧。放牧强度可以分为四种，分别为：对照、轻度放牧强度、中度放牧强度、重度放牧强度。附件 14、15 中数据将选择划区轮牧的放牧强度分为：对照（NG，0 羊/天/公顷）、轻度放牧强度（LGI，2 羊/天/公顷）、中度放牧强度（MGI，4 羊/天/公顷）和重度放牧强度（HGI，8 羊/天/公顷）。实际中，也可以做如下的划分：对照（NG，0 羊/天/公顷）、轻度放牧强度（LGI，1-2 羊/天/公顷）、中度放牧强度（MGI，3-4 羊/天/公顷）和重度放牧强度（HGI，5-8 羊/天/公顷）。

植物的生长满足自身的生长规律，同时受到周围环境的影响。例如，降水、温度、土壤湿度、土壤 PH、营养等都决定植物的生长情况。当牧羊（家畜日食量为 1.8kg，即标准羊单位，也包括羊羔。大牲畜折算系数 6.0，比如牛、马、骆驼，大牲畜幼崽折算系数 3.0）对植物进行采食时，一方面植物的地上生物量减少；另一方面，放牧对植物有刺激作用，改变了植物原有的生长速率，适当的放牧会刺激植物的超补偿生长，同样不合理的放牧也会降低植物的生长速率。为了保证土壤达到合适的状态，找到放牧羊（标准羊）数量的阈值是问题的关键。

土壤沙漠化又被称为沙质沙漠化，是荒漠化的一种主要表现类型。沙漠化是在干旱、半干旱和部分半湿润地区的沙物质基础和干旱大风动力条件下，由于自然因素或人为活动的影响，致使自然的生态系统平衡性遭到破坏，出现了以风沙活动为主要标志，并逐渐形成风蚀、风积地貌景观的环境退化过程，使原来没有沙漠景观的地区出现了类似沙漠景观的环境变化。土壤板结化是指土壤打破了原有结构，表层的有机质遭到严重破坏而造成的，土壤板结原因很多，比如土壤贫瘠、容重过大、土壤质地太粘以及有机肥严重不足等。

土壤化学性质和物理性质是影响土壤肥力重要因素，土壤化学性质包括：土壤有机碳 SOC、土壤无机碳 SIC、土壤全碳 STC、全 N、土壤 C/N 比等；土壤物理性质包括：土壤湿度、土壤容重等。一般来说，在保持土壤化学性质等基本不变情况下，降水会增加土壤湿度，而土壤湿度增加会提高草场植被覆盖率，在良好的植被覆盖情况下可以适当提高放牧强度，在一定区域内，放牧强度越高意味着更多的放牧数量，在不考虑放牧补贴和价格波动情况下，更多放牧数量代表更高的放牧收益。

现代草地资源的经营应遵循可持续发展原则，在保证生态环境良性健康发展中寻求经济利益的最大化。可持续发展的定义是：“可持续发展是经济规模增长没有超越生物环境承载能力的发展”。其理念是“可持续发展的整个理念就是经济子系统的增长规模绝对不能超越生态系统可以永远持续或支撑的容纳范围”。在草原区域系统中，承载力是评价可持续发展的一种工具。

1.2 问题的提出

根据附件数据以及收集有关草原数据（土壤容重、土壤 PH 等），通过数学建模完成下列问题：

问题 1：建立不同放牧策略对土壤湿度和植被生物量影响模型

从机理分析的角度，建立不同放牧策略（放牧方式和放牧强度）对锡林郭勒草原土壤物理性质（主要是土壤湿度）和植被生物量影响的数学模型。

问题 2：建立模型预测 2022 年、2023 年不同深度土壤湿度

根据土壤湿度数据、土壤蒸发数据以及降水等数据，建立模型对保持目前放牧策略不变情况下对 2022 年、2023 年不同深度土壤湿度进行预测，并将结果分别填入表中。

问题 3：建立不同放牧策略对土壤化学性质影响模型

从机理分析的角度，建立不同放牧策略（放牧方式、放牧强度）对锡林郭勒草原土壤化学性质影响的数学模型。并结合相关数据预测锡林郭勒草原监测样地(12 个放牧小区)在不同放牧强度下 2022 年土壤同期有机碳、无机碳、全 N、土壤 C/N 比等值,并填入对应表中。

问题 4：建立放牧策略模型

利用沙漠化程度指数预测模型和附件提供数据（包括自己收集的数据）确定不同放牧强度下监测点的沙漠化程度指数值。并给出定量的土壤板结化定义，在建立合理的土壤板结化模型基础上结合问题 3，给出放牧策略模型，使得沙漠化程度指数与板结化程度最小。

问题 5：建立最大放牧羊群优化模型

锡林郭勒草原近 10 年的年降水量（包含降雪）通常在 300 mm ~1200 mm 之间，请在给定的降水量（300mm，600mm、900 mm 和 1200mm）情形下，在保持草原可持续发展情况下对实验草场内（附件 14、15）放牧羊的数量进行求解，找到最大阈值。（注：这里计算结果可以不是正整数）

问题 6：牧户土地状态预测及演示

在保持附件 13 的示范牧户放牧策略不变和问题 4 中得到的放牧方案两种情况下，用图示或者动态演示方式分别预测示范区 2023 年 9 月土地状态（比如土壤肥力变化、土壤湿度、植被覆盖等）。

二、总体技术路线图

本文技术路如下：




图 1 全文技术路线图

三、基本假设与符号说明

3.1 基本假设

建模过程中，为了简化问题排除无关因素的干扰，根据锡林郭勒草原自然情况和文中所给条件进行了以下假设：

假设 1：附件给的数据真实可靠，所收集的数据也是真实可靠的；

假设 2：草原的环境在最近几年是遵循自然发展规律，不发发生太大的变化；

假设 3：只考虑次系统闭环状态下的情况，不考虑自然灾害以及人为破坏；

假设 4：在第四问和第五问中假设放牧方式全年是不发生变化的；

假设 5：在优化主要变量时认为所提出的预测模型结果准确。

3.2 符号说明

符号表示	含义说明
w	植被生物量
β	土壤含水量
S	单位面积的载畜率
P	降水量
H	土壤湿度
E	信息熵
C	土壤有机碳含量
C'	土壤无机碳含量
N	土壤全氮含量
Q_i	沙漠化因子集合
W_i	沙漠化因子权重集合
SM	沙漠化程度指数
B	土壤板结化指数
c	土壤容重
O	有机物含量

注：未列出符号及重复的符号以出现处为准

四、问题一的求解：放牧自然演变模型

4.1 问题分析

根据问题一要求，需要根据机理分析来建立不同放牧策略（放牧方式和放牧强度）对锡林郭勒草原土壤物理性质（主要是土壤湿度）和植被生物量影响的数学模型。由于放牧过程实际上是一个连续的演变过程，因此可针对土壤物理性质和植被生物量影响分别建立两个自然演变模型。根据已知条件与查阅相关资料可知，放牧过程的连续演变过程为：

Step1: 放牧环境初始化：循环过程初始值 t_0 、植被生物量 w_{t_0} 、土壤含水量 β_{t_0} ，并进入循环，更新循环时间；

Step2: 分别讨论采用不同的放牧策略（放牧方式和放牧强度）下对自然演变各循环中植被的生长速度和土壤湿度的影响；

Step3: 设计微分方程，得到植被生长速度的变化模型和土壤湿度的变化模型，以量化循环过程中的植被生长情况和土壤湿度情况。

Step4: 更新循环时间，并根据以上两个变化模型更新植被生物量和土壤含水量（湿度）等条件，进入下轮循环（返回 Step2）。

以上的放牧过程的连续演变过程如下图所示：




图 2 放牧过程的连续演变过程

从机理分析的角度来讲，采用不同的放牧策略，如过度放牧会因牲畜密度过大而导致草原植被破坏，并促进土壤的水分蒸发和土壤积盐与脱盐平衡，进一步导致土壤盐碱化程度加重；适度放牧可以改善草原土壤质量、提高草原生物的多样性^[2]。此外，不同的自然条件，如降水和土壤蒸发使得土壤的含水量发生变化，进而影响土壤的湿度。因此，影响植被生物量^[3]和土壤物理性质的因素主要有放牧策略和自然条件。

根据以上影响因素对 Woodward 等人建立的放牧与植物生长模型和土壤含水量-降水量-地表蒸发模型进行改进得到植被生物量演变模型和土壤物理性质演变模型。最后整合原始数据与搜集的数据设计实验讨论所得的模型的准确性以及鲁棒性。问题一的思路流程图如下：




图 3 问题一思路流程图

4.2 模型建立

4.2.1 机理分析

从机理分析的角度来讲，采用不同的放牧策略，如过度放牧会因牲畜密度过大而导致草原植被破坏，并促进土壤的水分蒸发和土壤积盐与脱盐平衡，进一步导致土壤盐碱化程度加重；适度放牧可以改善草原土壤质量、提高草原生物的多样性。此外，不同的自然条件，如降水和土壤蒸发使得土壤的含水量发生变化，进而影响土壤的湿度。因此，影响植被生物量和土壤物理性质的因素主要有放牧策略和自然条件。

当动物对植物进行采食时，一方面植物的地上生物量减少；另一方面，放牧对植物有刺激作用，改变了植物原有的生长速率，适当的放牧会刺激植物的超补偿生长，同样不合理的放牧也会降低植物的生长速率。

综上，植被生物量和土壤物理性质以及动物生长和植被生长过程是相辅相成并且是连续循环的，考虑以上因素，可建立植被生物量和土壤物理性质（湿度）的放牧自然演变模型。

4.2.2 植被生物量演变模型

对于放牧与植物生长之间的关系，Woodward 等建立了如下一个简单模型^[8]：

$$\frac{dw}{dt} = 0.049w\left(1 - \frac{w}{4000}\right) - 0.0047Sw \quad (1)$$

式中， w 为植被生物量； S 为单位面积的载畜率，即放牧强度，以标准羊为单位，大牲畜折算系数为 6.0，比如牛、马、骆驼，大牲畜幼崽折算系数为 3.0。

由于该模型只考虑放牧影响，简单地反映了载畜率对植被生物量的作用，没有考虑其他因素的影响，只是从某一个侧面刻某一个因素对于植被生长的影响，因此对其进行改进。

在演变过程中，当 $t = t_0$ 时，植被的生长速度 v_0 为：

$$v_0 = 0.049w_0\left(1 - \frac{w_0}{4000}\right) - 0.0047Sw_0 \quad (2)$$

式中， w_0 为植被生物量的初始值。根据 t_0 时刻的植被生长速度可以得到下一时刻 t_1 的植物生物量 w_1 为：

$$w_1 = w_0 + \int_{t_0}^{t_1} v_0 dt \quad (3)$$

由于每个时刻的植被生物量不同且放牧强度 S 和放牧方式 M 改变造成土壤环境发生改变，同时考虑降水、蒸发等环境因素，可得动态影响方程

$$\alpha_t = f(w_{t-1}, P_{t-1}, C_{t-1}, S, M) \quad (4)$$

式中, w_{t-1} 为上一时刻的植被生物量, P_{t-1} 为上一时刻的降水量, C_{t-1} 为上一时刻的土壤蒸发量。根据上式可对植被的生长速度方程做出改进, 改进后的植被的生长速度方程如下:

$$v_i = \alpha_i [0.049w_0 \left(1 - \frac{w_0}{4000}\right) - 0.0047Sw_0] \quad (5)$$

最终的生物量演变模型为:

$$w_n = w_0 + \sum_{i=2}^n \int_{i-1}^i v_{i-1} dt \quad (6)$$

4.2.3 土壤湿度演变模型

对于土壤含水量与降水量和地表蒸发的关系, 可以按以下土壤含水量-降水量-地表蒸发模型建模:

$$\frac{d\beta}{dt} = P - E(a) \quad (7)$$

式中, P 为该牧区供水率(主要为降水), E 为地表蒸散发率, β 为土壤含水量, a 为土壤植被覆盖率可表达为 $\alpha^*G(w)$, w 为成草数量, $G(w) = (1 - e^{-\varepsilon_g w/w^*})$ 为草原的盖度。为考虑放牧策略的影响和简化模型, 对以上模型做出如下改进:

$$v'_i = \frac{d\beta}{dt} = P_i - F_i \quad (8)$$

式中, v'_i 为 i 时刻的地表含水速率, P 为该牧区供水率(主要为降水), F 为地表蒸散发率。根据 t_0 时刻的地表含水速率可以得到下一时刻 t_1 的土壤含水量 β_1 为:

$$\beta_1 = \beta_0 + \int_{t_0}^{t_1} v'_0 dt \quad (9)$$

考虑放牧影响土壤的水分蒸发以及环境条件, 对土壤湿度模型建模为:

$$H_i = a\beta_i + bS + c \quad (10)$$

式中, S 为放牧强度, c 为环境影响因子, a 、 b 为土壤含水量与放牧策略的平衡因子, β_i 为 t_i 时刻的土壤含水量, 计算方程如下:

$$\beta_n = \beta_0 + \sum_{i=2}^n \int_{i-1}^i v'_{i-1} dt \quad (11)$$

4.2.4 基于植被指数（NDVI）的植被地上生物量模型

下表列出了基于植被指数 NDVI 的植被地上生物量线性模型和 3 类非线性模型（对数、二次多项式、三次多项式）的复相关系数^[9]。对于 NDVI 而言，三次多项式地上生物量回归模型（ $R^2 = 0.832$ ）好于对数模型（ $R^2 = 0.773$ ）、二次多项式模型（ $R^2 = 0.772$ ）和线性模型（ $R^2 = 0.771$ ）。

由上述可知，植被生物量的线性模型与非线性模型都表现出较好的模拟效果，都通过了 0.01 的显著性检验，即 R^2 值均大于 0.6。表现出三次多项式生物量回归模型最优，其次是对数模型，再次是二次多项式生物量模型，相对较差的是线性模型，其复相关系数较小。

表 1 植被指数 NDVI 与植被地上生物量的回归模型

模型类型	模型	复相关系数
线性	$y = 4.033x - 515.400$	$R^2 = 0.771$
对数	$y = 687.180 \ln(x) - 3356.500$	$R^2 = 0.773$
二次多项式	$y = -0.007x^2 + 6.362x - 714.010$	$R^2 = 0.772$
三次多项式	$y = 0.003x^3 - 1.748x^2 + 301.240x - 17238.000$	$R^2 = 0.832$

4.3 模型求解与检验

4.3.1 植被生物量演变模型求解与检验

由于植被生物量演变模型中包含动态影响方程，该方程需实际的数据进行求解计算，因此搜集相关文献获得数据求解模型，并使用整合的附件数据进行模型检验。

1) 准确性检验

从附件中随机采集 80 个时间段的植被干重、放牧群落结构、降水等数据，经查询相关文献，以植被干重作为植被生物量、放牧群落结构为放牧强度。为检验改进后的模型的准确性，分别使用 Woodward 等人建立的模型和生物量演变模型计算这 80 个时间段的植被生物量变化，所得的性能对比表和结果图分别如下：

表 2 模型改进前后性能对比

模型类型	RMSE	MAE	拟合度 R2
Woodward 等人建立的模型（改进前）	513.752	423.765	0.133
生物量演变模型（改进后）	221.605	174.644	0.839




图 4 植被生物量变化预测对比图

通过实验对比可以发现，不管是在 RMSE、MAE 指标还是 R2 指标中，改进后得到的植被生物量演变模型的性能是最佳的，反映了本文提出的植被生物量演变模型的准确性高。

2) 鲁棒性检验

为检验改进后的模型的鲁棒性，采用同以上一样的数据，改变环境的植被生物量初始值 w_0 来增加扰动，分别使用 Woodward 等人建立的模型和生物量演变模型计算这 80 个时间段的植被生物量变化，所得的损失对比表和结果图分别如下：

表 3 模型损失对比

模型类型	RMSE	MAE	拟合度 R2	损失
改进前模型	513.752	423.765	0.133	-
改进前模型+扰动	538.294	455.915	0.048	63.91%
改进后模型	221.605	174.644	0.839	-
改进后模型+扰动	274.765	154.161	0.752	10.37%




图 5 植被生物量变化预测对比

通过实验对比可以发现，在对两模型增加扰动后，改进前的模型性能损失为 63.91%，而改进后得到的植被生物量演变模型性能损失仅为 10.37%，因此，改进后得到的植被生物量演变模型在应对环境变化的扰动时性能依然稳健，反映了本文提出的植被生物量演变模型的鲁棒性强。

4.3.2 土壤湿度演变模型求解与检验

从附件中选取 2012-2022 年内蒙古锡林郭勒草原的土壤湿度、降水、土壤蒸发量、放牧群落结构等数据，经查询相关文献，以 200cm 湿度作为土壤湿度、放牧群落结构为放牧强度。使用 80% 的数据求解模型、20% 的数据检验模型的准确性，并通过灵敏度分析来检验模型的鲁棒性。

经模型求解后所得的土壤湿度演变模型如下：

$$H_i = 1.533\beta_i - 0.297S + 166.936 \quad (12)$$

1) 准确性检验

由于土壤的湿度主要来自于自然的降水与蒸发（即土壤含水量）且呈正相关；而放牧活动会影响土壤的松动促进土壤中的水分蒸发，因此土壤湿度与放牧活动呈负相关且影响小于自然降水。土壤湿度演变模型如上所示，土壤含水量的相关系数为 1.533，放牧强度的相关系数为-0.297，且调节因子 166.936 在合理的范围之内，符合分析，初步证明了所建立模型的准确性高。

为进一步检验改进后的模型的准确性，分别使用土壤含水量-降水量-地表蒸发模型和土壤湿度演变模型计算验证数据的土壤湿度，所得的性能对比表和结果图分别如下：

表 4 模型改进前后性能对比

模型类型	RMSE	MAE	拟合度 R2
土壤含水量-降水量-地表蒸发模型（改进前）	0.662	0.434	0.295
土壤湿度演变模型（改进后）	0.482	0.385	0.626




图 6 土壤湿度预测对比

通过实验对比可以发现，不管是在 RMSE、MAE 指标还是 R2 指标中，改进后得到的土壤湿度演变模型的性能是最佳的，进一步反映了本文提出的植被生物量演变模型的准确性高。

2) 鲁棒性检验

为检验土壤湿度演变模型的鲁棒性，对模型进行敏感性分析。从以上的数据数据中随机选取一个样本，采用控制变量法保持其他变量取值不变，将建模主要变量降水量和土壤蒸发量在-20%至 20%幅度范围内以 5%为步长进行波动，每次波动后通过建立的土壤湿度演变模型预测土壤湿度，得到土壤湿度与变量波动幅度之间的结果表和敏感性分析图如下所示：

表 5 敏感性分析结果

变量名称/ 波动幅度	-20%	-15%	-10%	-5%	5%	10%	15%	20%
降水量	168.1594	168.1594	168.1594	168.1594	168.1594	168.1594	168.1594	168.1594
	06	11	16	21	31	36	42	47
土壤蒸发量	168.1594	168.1594	168.1594	168.1594	168.1594	168.1594	168.1594	168.1594
	31	30	29	27	25	24	23	22




图 7 土壤湿度与变量波动幅度敏感性分析

由上述图表可知，在误差允许的范围内：降水量的正向幅度增大使得土壤湿度增大，土壤蒸发量的正向幅度增大使得土壤湿度减小，这符合机理分析；在两个变量(降水量、土壤蒸发量)不同幅度的波动下，土壤湿度的变化幅度不大（在数量级 $1e-5$ 之内），这说明土壤湿度演变模型受小幅度的波动影响不大，鲁棒性强。

五、问题二的求解：LSTM 未来序列预测模型

5.1 问题分析

本题要求建立模型对保持目前放牧策略不变情况下对 2022 年、2023 年不同深度土壤湿度进行预测。换句话说，在保持目前放牧策略不变情况下，使用附件 3 土壤湿度数据、附件 4 土壤蒸发数据以及附件 8 中降水等数据作为输入值，使用 2022 年、2023 年不同深度土壤湿度作为待预测值，通过构建模型建立与土壤湿度相关特征与土壤湿度的关系。但是由于后面两年的土壤蒸发量和降水量等数据未知，用常规的回归和时间序列方法很难解决当前问题。

问题二的关键在于如何根据历史的土壤蒸发量和降水量等数据和不同深度土壤湿度数据预测出未来的不同深度土壤湿度数据，重要的是让模型探索出土壤蒸发量和降水量等特征和不同深度土壤湿度的潜在隐藏关系，同时还需要模型具有根据当前年数据预测下一年数据的能力。本文为了达到这种目的，巧妙利用了 LSTM-FC 这一神经网络模型，它可以很好的构建起输入与输出之间的逻辑关系。同时注意到同一年的不同月土壤湿度变化较为剧烈且具有随机性，如果把整个待预测时间段交给同一个模型预测，误差会不断传播，距离历史数据时间越久远就越难预测，分成不同月单独训练模型可以有效避免这个问题，因此以每一个月的历史特征数据作为输入来让模型预测未来这个月的特征，分别训练用于

预测 12 个不同月份的 12 个独立模型。

同时，注意到题目要求使用土壤蒸发量和降水量等数据，说明根土壤湿度相关的特征可能不只是土壤蒸发量和降水量，因此合并与土壤湿度相关的所有数据集，进行数据整理后，筛选出与土壤湿度相关的重要特征，并进行独立性检验和代表性检验，进而送入模型训练和预测，额外的特征能辅助构建与土壤湿度特征的关系。




图 8 问题二的思路流程图

最终，本题的思路流程图如上所示，首先合并所有可能与土壤湿度相关的数据集，对数据进行冗余数据与特征过滤，然后，分别将 10cm、40cm、100cm、200cm 不同深度的土壤湿度作为因变量用随机森林筛选出重要特征，合成综合的土壤湿度相关的重要特征，并进行特征独立性检验和特征代表性检验。然后使用了集成多种分类器的集成(Stacking)模型和 LSTM 模型来建立回归模型；其次通过实验对两种方法进行对比，阐述两者的优劣；最后，通过验证阐述模型的有效性，并对未来不同深度土壤湿度进行结果预测。

5.2 数据分析与预处理

首先合并所有可能影响到土壤湿度的特征数据，包括土壤湿度、土壤蒸发量、植被指数、径流量以及锡林郭勒盟气候数据，共得到 123 个样本，33 个特征。由于这些数据由机器或人为测定，可能存在设备偏差和人为偏差，直接放入模型中会导致效果不佳。在模型训练与预测之前需要对数据进行预处理，因此主要做了以下工作：

5.2.1 缺失值与异常值检测

对于合并后的数据，首先对特征维度进行缺失值检测，剔除掉了数据中的“积雪深度(mm)”、“平均最大瞬时风速(knots)”、“最大瞬时风速极值(knots)”这三个特征。之后检测特征维度和样本维度上不满足 3σ 准则的异常值，发现异常值很少，不做删除。

5.2.2 重复特征过滤

如果该整型变量的 90% 样本的描述符值是相同的，则说明该描述符对每个化合物都一样，属于无关特征，可以直接删除这个特征，公式如下：

$$MSE = (y_i - y'_i)^2 \quad (13)$$

$$\max \left(\frac{\sum_{i=0}^n count(i)}{n} \right) > threshold \quad (14)$$

对于 *threshlod* 阈值的选择，从 0 至 1 每 0.1 取一点进行特征筛选数量对比，见下图所示，由于本身数据特征数量较少，因此将重复率大于 0.7 的特征视为无关特征（共计 2 个）并删除。




图 9 不同阈值删除特征数图

通过对数据的预处理，筛除了缺失、异常与冗余数据，剩余 28 个特征，减少了特征的维度，减少了后续模型训练拟合的难度。

5.3 基于随机森林的综合重要特征筛选

随机森林（Random forest，简称 RF）是由美国科学家 Leo Breiman 于 2001 年发表的一种机器学习算法[8]。作为一种新兴起、高度灵活的机器学习算法，其拥有广泛的应用前景，在大量分类以及回归问题中具有极好的准确率。并且，随机森林算法自带特征筛选机制，即随机森林能够评估各个特征在相应问题上的重要性。在本题中，针对分子描述符变量数量多、高度非线性、耦合度高的特点，选择嵌入式特征选择方法随机森林进行数学建模，以期望得到前 20 个对生物活性最具有显著影响的分子描述符变量。

5.3.1 随机森林训练

随机森林是以 K 个决策树 $\{h(X, \theta_k), k=1, 2, \dots, K\}$ 为基本分类器，进行集成学习后得到的一个组合分类器。当输入待分类样本时，随机森林输出的分类结果由每个决策树的分类结果简单投票决定。这里的 $\{\theta_k, k=1, 2, \dots, K\}$ 是一个随机变量序列，它是由随机森林的两大随机化思想决定的：

Bagging 思想：从原样本集 X 中有放回地随机抽取 K 个与原样本集同样大小的训练样本集 $\{T_k, k=1, 2, \dots, K\}$ ，每个训练样本集 T_k 构造一个对应的决策树（本文设定 $=500$ ）。

特征子空间思想：在对决策树每个节点进行分裂时，从全部属性中等概率随机抽取一个子集（通常取 $\log_2(M)+1$ 个属性，为特征总数），再从这个子集中选择一个最优属性来分裂节点（本文设定 $M=150$ ）。

训练随机森林的过程就是训练各个决策树的过程，由于各个决策树的训练是相互独立的，因此随机森林的训练可以通过并行处理来实现，这将大大提高生成模型的效率。随机森林的训练流程如图 10 所示。

5.3.2 特征重要性计算

随机森林算法可以在分类的基础上进行回归分析，通过将样本分类的结果进行一定的运算可以获得各个特征重要性特征的重要性表示特征对预测结果影响程度，某一特征重要性越大，表明该特征对预测结果的影响越大，重要性越小，表明该特征对预测结果越小。随机森林算法中某一特征的重要性，是该特征在内部所有决策树重要性的平均值，而在决策树中，计算某一个节点 k 的重要性

$$n_k = w_k * G_k - w_{left} * G_{left} - w_{right} * G_{right} \quad (15)$$

其中， w_k, w_{left}, w_{right} 分别为节点 k 以及其左右节点中训练样本与总训练样本数目的比例， G_k, G_{left}, G_{right} 分别为节点 k 以及其左右子节点的不纯度。得到每一个节点的重要性之后，即通过公式的得出某一特征的重要性。

$$f = \frac{\sum_{j \in \text{nodes split on feature } i} n_j}{\sum_{k \in \text{all nodes}} n_k} \quad (16)$$




图 10 随机森林训练过程流程图

通过上述随机森林筛选模型实现和特征重要性计算方法，分别得到对于 10cm、40cm、100cm、200cm 深度的土壤湿度对应的重要特征重要性得分如下：




图 11 土壤 10cm 湿度重要特征分析图




图 12 土壤 40cm 湿度重要特征分析图




图 13 土壤 100cm 湿度重要特征分析图




图 14 土壤 200cm 湿度重要特征分析图

对每个模型得到的重要性特征从大到小排序后取前十个并进行合并，最后得到如下重要特征：'最大单日降水量(mm)', '降水天数', '土壤蒸发量(W/m2)', '植被指数(NDVI)', '平均风速(knots)', '平均最大持续风速(knots)', '最小能见度(km)', '单日最大平均风速(knots)', '平均露点温度(°C)', '降水量(mm)', '土壤蒸发量(mm)', '径流量(m3/s)', '径流量(m3)', '平均能见度(km)', '平均站点气压(hPa)'。

5.3.3 强相关性特征过滤

虽然筛选出的特征在对土壤湿度都有显著影响，但是某些重要特征之间存在很强的相关性，仍然属于冗余特征，需要将这些特征剔除掉从而简化模型提高效率。

斯皮尔曼(Spearman)相关系数：又称斯皮尔曼秩相关系数，是秩相关系数的一种。“秩”，即秩序，可以理解作为一种顺序或排序[4]，根据变量在数据内的位置进行计算，公式为：

$$\rho = 1 - \frac{6 \sum d_i^2}{n(n^2 - 1)} \quad (17)$$

与皮尔逊相关系数相比，斯皮尔曼相关系数没有数据连续性和分布方式限制，不需要关心数据如何变化,符合什么样的分布，只需要关心每个变量对应数值的位置。如果两个变量的对应值，在各组内的排列顺位是相同或类似的，则具有显著的相关性。

对上述处理后的特征绘制相关性热力图如下：




图 15 特征相关性热力图

经过观察发现, '最小能见度(km)', '平均能见度(km)'相关性值为 0.79, '最大单日降水量(mm)', '降水量(mm)'相关性值为 0.94。与温度相关特征, 与风速相关特征, 与气压相关特征等这些特征类别之间存在很大的相关性, 应从其中删除一部分。同时注意到, '土壤蒸发量(W/m²)', '平均露点温度(°C)'相关性值为 0.9, 结合文献查阅, 二者确实具有很强的相关性。根据相关性热力图和文献调查, 最后确定与土壤湿度相关的四个重要特征: '降水量(mm)', '土壤蒸发量(mm)', '平均能见度(km)', '径流量(m³)'。

5.3.4 特征独立性与代表性检验

(1) 独立性验证

当主要变量两两之间相关性均较弱时, 某种意义上任何主要变量均可独立的描述因变量的某方面性质, 此时主要变量具有一定的独立性。参照上述随机森林特征筛选模型的结果:对 4 个与土壤湿度相关特征进行了相关性热力图可视化, 见下图。可见, 变量之间的独立性较好, 满足特征变量独立性的要求。




图 16 4 个变量的相关性热图

(2) 代表性验证

“信息熵”理论：香农于 1948 年提出了“信息熵”理论。一般来说，某个指标的信息熵越小，计算出来的信息熵权重也就越大，相应提供的信息量越多，其在综合模型的重要程度也越大；相反，某个指标的信息熵越大，其所占信息熵权重则越小，提供的信息量也越少，在综合模型中所起到的作用也越小。其中，对于某项指标的一组数据，其信息熵权重的计算方式如下所示：

$$p_{ij} = Y_{ij} / \sum_{i=1}^n Y_{ij} \quad (18)$$

$$E_j = -\ln^{-1}(n) \sum_{i=1}^n p_{ij} \ln p_{ij} \quad (19)$$

$$W_j = \frac{1 - E_j}{n - \sum_{i=1}^n E_i} (j = 1, 2, \dots, n) \quad (20)$$

其中， E_j 为第 j 项指标的信息熵， n 为样本总数， Y_{ij} 为该指标的第 j 条样本数据。 W_j 是第 j 个筛选后主要变量的信息熵权重。筛选后的主要变量的信息熵、信息熵权重和信息熵累积权重如下表所示：

表 6 四个特征信息熵权重及其累计值

名称	降水量(mm)	土壤蒸发量(mm)	平均能见度(km)	径流量(m3)
信息熵权重	0.0851	0.0712	0.0563	0.0435
信息熵累积权重	0.0851	0.1563	0.2126	0.2561




图 17 变量筛选及其权重展示图

首由上述图表可知，4 个主要变量的累积信息熵权重为 0.2561，即 4 个主要变量的信息熵占比已达到全部 28 个变量信息熵总和的 25.61%（平均水平为 $4/28=14.29\%$ ），由此，说明所选择的 4 个主要变量具有一定的代表性。

结合特征筛选和特征独立性代表性验证，最终确定了八个特征作为后续模型训练，分别是待预测的四个特征：'10cm 湿度(kg/m2)', '40cm 湿度(kg/m2)', '100cm 湿度(kg/m2)', '200cm 湿度(kg/m2)'以及 与土壤湿度相关的四个重要特征：'降水量(mm)', '土壤蒸发量(mm)', '平均能见度(km)', '径流量(m3)'。加入比题目要求多出的两个特征，即'平均能见度(km)', '径流量(m3)'，这更有利于模型学习到土壤湿度与和它相关重要特征之间的联系，从而提升模型性能。

5.4 建型的建立与求解

5.4.1 数据分布观察与可视化

首先，对所有年份所有月份的八个特征进行宏观统计。由于他们都是连续的浮点型变量，进行统计，并绘制每个变量的分布图，如下图所示。可以在图中看出'10cm 湿度(kg/m2)', '40cm 湿度(kg/m2)', '100cm 湿度(kg/m2)', '200cm 这些土壤湿度特征分布范围，后期可用于验证模型预测的正确性。




图 18 不同湿度和四个特征分布范围图

同时为了决定 LSTM 建模方式，绘制了不同年份同一月份这些特征的变化曲线以及相同年份不同月份的特征变化曲线。以下图所有年的 4 月和 2020 年的所有月的曲线为例，注意到同一年的不同月土壤湿度变化较为剧烈且具有随机性，如果把整个待预测时间段交给同一个模型预测，误差会不断传播，距离历史数据时间越久远就越难预测。而对于不同年的同一月，变化则具有一定的规律性，按月分开建模能使模型获取到更好的效果。




图 19 土壤不同湿度和四个特征随时间连续变化图




图 20 土壤不同湿度和四个特征不同月按年变化图

表 7 回归分析方法比较

	方法描述	优缺点
回归算法	采用对误差的衡量来探索因变量和自变量之间的关系，如线性回归、逻辑回归等	建模迅速，适用于小数据量、简单的关系，对非线性的数据拟合不好
正则化方法	通常是回归算法的延伸，根据算法的复杂度对算法进行调整。如 LASSO 回归、岭回归等	可以防止过拟合和提高模型泛化性能，但会造成欠拟合
决策树学习	根据数据的属性采用树状结构建立决策模型。如分类及回归树，C4.5，随机森林（Random Forest）等	具有很高的复杂度和高度的非线性关系，模型容易解释，但存在过拟合倾向，运行速度慢和内存消耗高
集成算法	由多个相对较弱的学习模型独立地就同样的样本进行训练，将预测结果以某种方式整合起来进行总体预测。如 Boosting，Bagging，AdaBoost，梯度推进机（Gradient Boosting Machine, GBM）等	当先最先进的预测几乎都使用了集成算法。精确率高于其他单个模型预测出来的结果

5.4.2 基于数据驱动模型调研

针对问题二的要求，需要建模上文刷选八个特征与不同土壤湿度的模型，因此问题二为数据驱动型题目。数据挖掘技术应用于土壤湿度模型的建立，是通过数据驱动的方式，根据采集数据建立模型，从而学习内在逻辑规律。

5.4.3 长短期记忆网络（LSTM）介绍

长短记忆网络（LSTM）^[4]是在 RNN 的基础上变形得到的，能够有效缓解梯度消失和梯度爆炸的问题，获取时间上的连续信息，适合建模问题二土壤湿度。




图 21 LSTM 结构图

LSTM 的结构如图 2.1 所示，以上主要由输入门、遗忘门和输出门三个门控机制组成。以下是对三个门限模块进行详细介绍。

1. 遗忘门，式（21）上个网络层隐藏状态和当前输入数据作为输入，以用于控制上个单元状态保留值。

$$f_t = \sigma(W_f \cdot [h_{t-1}, x_t] + b_f) \quad (21)$$

2. 输入门，用以决定输入上一单元的隐藏层和当前输入应该保留多少以及临时单元信息，如式（22）与式（23）：

$$i_t = \sigma(W_i \cdot [h_{t-1}, x_t] + b_i) \quad (22)$$

$$\tilde{C}_t = \tanh(W_c \cdot [h_{t-1}, x_t] + b_c) \quad (23)$$

3. 更新当前的单元信息，如式（24）：

$$c_t = f_t * C_{t-1} + i_t * \tilde{C}_t \quad (24)$$

4. 输出门，用来得到输出信息，如式（25）与式（26）所示：

$$o_t = \sigma(W_o \cdot [h_{t-1}, x_t] + b_o) \quad (25)$$

$$h_t = o_t \times \tanh(C_t) \quad (26)$$

由于输入门以及遗忘门的存在，LSTM 可以删除或增加神经元状态中的信息，这是 LSTM 精心设计的门限结构。门限是由线性网络和 sigmoid 激活函数组成，本质是通过非线性变化选择信息，由 sigmoid 函数和矩阵参数控制。sigmoid 函数的作用是使其输出在 [0,1] 区间，可以等效为一组权重值。当输出值为 0，遗忘门将遗忘所有上阶段信息；当输出值为 1，遗忘门将保留所有上阶段信息。

因此，LSTM 选择性遗忘或保留的能力能够有效解决标准循环神经网络在信息过长时面临的梯度弥散或梯度爆炸问题，有利于信息建模，同时可以更好建模具有时序关系和较多变量影响的土壤湿度模型。

5.4.4 基于 LSTM-FC 网络的土壤湿度预测模型

考虑到本文中 22 年到 23 年的预测数据没有特征，因此使用 LSTM-FC 模型同时预测特征和土壤湿度。由上文分析得土壤湿度同月不同年的数据存在周期性变化，但是同年不同月的数据较为混乱，因此分别对 12 个月的土壤湿度建模，模型说明情况如下图所示。




图 22 土壤湿度预测模型汇总图

对土壤湿度进行预测的模型建立中，需要明确数据的数量和维度，由于 2022 年仅仅包含 1 月到 3 月的数据，因此 1 月至 3 月每个月的数据为 10 个样本，4 月至 12 月每个月数据为 9 个样本，数据输入和输出维度信息见下表。

表 8 训练集、测试集的维度

	输入(X)	输出(Y)
1 至 3 月数据	10×8	8×10
4 至 12 月数据	9×8	8×9

训练网络过程中使用的损失函数是均方误差函数式（27）

$$MSE = (y_i - y'_i)^2 \quad (27)$$

式中： y_i 表示土壤湿度值真实值， y'_i 表示土壤湿度预测值。

在土壤湿度预测中，LSTM-FC 网络的输入矩阵维度为(batch_size, input_dim)，经过 LSTM 网络层后输出矩阵维度为(batch_size, hidden_dim)，最后经过回归层得到预测值(batch_size, out_size)。这里 batch_size 为批训练数目，hidden_size 为隐藏层维数，out_size 为输出向量的维度，在预测时为 8。这里的叙述只是为了更加直观的理解采用了二维输入，但在实际编写程序的 LSTM 网络中需要转化为三维输入。模型每个模块使用激活函数连接，其中 LSTM 间使用 relu 函数，加快模型训练速度，Fc 间使用 sigmoid 函数降低模型对于数据的敏感性。

综上建立的每个月的具体土壤预测模型结构以及中间维度变化如下图所示。




图 23 LSTM-FC 结构图

5.4.5 其他模型的预测方法

为了验证 LSTM-FC 的有效性，采用以下方法做对照实验。

- 支持向量机回归（SVR）：支持向量机回归，顾名思义就是用支持向量机来进行回归预测，而支持向量机是一种按监督学习方式对数据进行二元分类的广义线性分类器，其决策边界是对学习样本求解的最大边距超平面。
- 随机森林回归（rf）：使用随机的方式建立一个森林，森林里面有很多的决策树组成，随机森林的每一棵决策树之间是没有关联的。
- 梯度提升回归（GBR）：梯度提升算法是一种通用的学习算法，除了决策树，还可以使用其它模型作为基的学习器。梯度提升算法的思想是通过调整模型，让损失函数的值不断减小，然后将各个模型加起来作为最终的预测模型。而梯度提升决策树则是以决策树为基的学习器。
- 基于 Stacking 的回归：是一种分层模型集成框架，在本题中，初级学习算法使用以上四种方法，次级学习器使用线性回归模型。

5.4.6 评价指标

在本小节中，采用四个评价指标对各个模型的回归预测结果进行评估：

1) 均方根误差（RMSE）

均方根误差（RMSE）是指参数估计值与参数真值之间的偏差，常作为机器学习回归问题的衡量指标，RMSE 的值越小，说明预测模型描述实验数据具有更好的精确度，其计算公式如下：

$$MSE = \sqrt{\frac{1}{N} \sum_{t=1}^N (R_t - P_t)^2} \quad (28)$$

其中， N 表示样本数， R_t 表示 t 样本对应的真实值， P_t 表示 t 样本对应的预测值。

2) 平均绝对误差（MAE）

平均绝对误差（MAE）是所有单个观测值与算术平均值的偏差的绝对值的平均，平均绝对误差可以避免误差相互抵消的问题，因而可以准确反映实际预测误差的大小。此外，由于离差被绝对值化，不会出现正负相抵消的情况，其计算公式如下：

$$MAE = \frac{1}{N} \sum_{t=1}^N |R_t - P_t| \quad (29)$$

3) 可决系数（ R^2 ）

可决系数反映的是预测值对实际值的解释程度。其公式如下

$$R^2 = 1 - \frac{\sum (R_t - P_t)^2}{\sum (R_t - \bar{R})^2} \quad (30)$$

其中，分母代表原始数据的离散程度，分子为预测数据和原始数据的误差，二者相除可以消除原始数据离散程度的影响。可决系数越接近 1，表明自变量对因变量的解释能力越强，这个模型对数据拟合的也较好，一般来说， $R^2 > 0.4$ ，认为拟合效果较好。

$$y = \frac{TP}{TP + FN} \quad (31)$$

5.4.7 模型结果分析

1) LSTM-FC 拟合结果图

使用网格搜索法，搜寻得到适用于土壤湿度预测的最优超参数为：网络层数为 6 层、学习率为 0.001、批处理数为 1、迭代次数为 100，用最优的模型拟合数据结果。因为存在 12 个月的土地湿度预测模型，这里每个季节挑选一个模型做展示，具体挑选 a2, a5, a8, a11，四种湿度的拟合效果如下图所示。



图 24 土地湿度 10cm 的四个月份预测结果比较图




图 25 土地湿度 40cm 的四个月份预测结果比较图




图 26 土地湿度 100cm 的四个月份预测结果比较图




图 27 土地湿度 200cm 的四个月份预测结果比较图

将 LSTM-FC 方法、对比方法中最好的 stacking 模型比较，stacking 模型并没有拟合数据之间的变化，LSTM-FC 的在数据变化趋势上的拟合效果明显优于 stacking 模型，因此模型可以学到同月不同年数据间的周期关系。

为了体现数据的连续性，将 12 个月的预测结果拼接在一起，将 stacking 的预测结果和 LSTM-FC 的预测结果分别与真实结果比较，土壤湿度 10cm 的比较如下图所示：




图 28 Stacking 模型和 LSTM-FC 模型拟合结果汇总比较图

从上图可以看出，左边的 stacking 的拟合效果明显收敛过度，右边的 LSTM-FC 可以很好的拟合原始数据，效果较优。

2) 指标结果对比

为了验证 LSTM-FC 对于土地湿度预测的合理性和准确性，对所建立的模型进行对比分析，使用 Python 语言进行编程，将 RMSE、MAE 以及 R2 这三个指标与 LSTM-FC 的指标对比，由于有四种湿度预测，因此对四种湿度的指标求均值结果如下表所示：

表 9 模型指标结果比较表

模型类型	RMSE	MAE	拟合度 R2
SVR	18.62	12.06	0.888
RF	17.96	11.81	0.896
Stacking	17.70	10.63	0.96
LSTM-FC	8.051	4.891	0.981

综上所述，采用 LSTM-FC 预测土壤湿度是可靠的，精度比较高，但是从 RMSE 结果上可以看到湿度预测依旧存在损失，这主要有两方面原因：（1）数据样本较少，对于数据驱动模型需要有足够数量的样本支撑相应结构大小的模型；（2）特征选择可能不是最优，这里从众多特征中筛选出 4 个特征，但是实际情况可能存在其他不在数据内的影响因子。

5.4.8 模型对 2022、2023 年预测结果

根据 LSTM-FC 模型预测未来 21 个月的 10cm、40cm、100cm 和 200cm 土壤湿度值，带入到问题 2 到 2022 年 4 月至 2023 年 12 月表格，如下表所示：

表 10 预测结果汇总表

年份	月份	10cm 湿度 (kg/m2)	40cm 湿度 (kg/m2)	100cm 湿度 (kg/m2)	200cm 湿度 (kg/m2)
2022	04	14.65	36.46	48.59	167.16
	05	16.05	35.86	42.79	167.39
	06	16.19	40.73	55.71	166.74
	07	21.80	60.31	80.34	165.86
	08	20.59	56.17	81.58	165.58
	09	20.89	58.95	85.88	165.23
	10	17.09	53.49	88.84	164.82
	11	14.21	51.38	91.90	164.75
2023	12	12.50	41.49	48.13	167.51
	01	13.53	50.82	84.81	165.22
	02	12.50	51.45	92.45	164.66
	03	14.81	51.39	92.60	164.73
	04	12.30	44.51	63.27	167.27
	05	14.60	45.32	64.97	166.79
	06	16.16	40.62	55.24	166.73
	07	21.80	60.28	80.25	165.87

	08	20.58	56.15	81.32	165.59
	09	20.88	58.94	85.87	165.23
	10	17.14	53.58	88.73	164.85
	11	14.21	51.39	91.91	164.75
	12	12.39	40.79	47.63	167.49

六、问题三的求解：土壤化学性质机理模型

6.1 问题分析

根据问题三的要求，分别有两个任务需要解决。第一个任务是通过机理分析，确定直接影响因子，结合问题一中的模型建立放牧策略对土壤化学性质（土壤的有机碳、无机碳、全氮、土壤 C/N 比）影响的数学模型，最后进行合理性分析证明所建立模型的准确性。第二个任务是根据附件中的放牧强度与土壤有机碳、无机碳、全氮等数据预测检测样本在不同放牧强度下 2022 年土壤同期有机碳、无机碳、全氮、土壤 C/N 比等值。

对于第一个任务，查阅相关资料，发现土壤中的有机碳、无机碳、全氮均满足质量守恒；通过机理分析确定有机碳、无机碳、全 N 的来源以及消耗的影响因子，并分析各分子的变化规律，根据它们的影响因子和变化规律并结合问题一中的模型来构建动态的有机碳、无机碳、全 N 的平衡方程。最后结合创建的放牧自然演变模型来得到不同放牧策略下的土壤化学性质的数学模型，并进行合理性分析。

对于第二个任务，分析并依据统计学原理处理附件中的放牧强度与土壤有机碳、无机碳、全 N 等数据，基于对本题数据量和模型简单通用的特点，拟建立简单高效的 GRU 模型预测检测样本在不同放牧强度下 2022 年土壤同期有机碳、无机碳、全氮值。问题三的思路流程图如下：




图 29 问题三的思路流程图

6.2 土壤化学性质机理模型的建立

查阅相关资料，发现土壤的化学性质（土壤的有机碳、无机碳、全氮）满足质量守恒，参考问题一所建立的自然演变模型可以对土壤的化学性质动态守恒建立如下图：

对土壤中的有机碳、无机碳、全氮等含量进行机理分析，并分别建立放牧策略对它们的数学模型：

1) 土壤有机碳 SOC

令土壤有机碳的含量为 C ，则在 t 时刻土壤有机碳的含量为 C_t ，得到随时间的土壤有机碳动态守恒方程：

$$C_t = C_{t-1} + \Delta C_t \quad (32)$$

$$\Delta C_t = C_{t\text{吸}} - C_{t\text{消}} \quad (33)$$

式中， $C_{t\text{吸}}$ 表示从 $t-1$ 时刻到 t 时刻土壤有机碳 SOC 的吸收量； $C_{t\text{消}}$ 表示从 $t-1$ 时刻到 t 时刻土壤有机碳 SOC 的消耗量。

对于土壤有机碳 SOC 的消耗量，根据参考文献得知土壤中的有机碳 SOC 的主要作用为用于植被生长，而小部分的有机碳会在水土流失中失去。由于在研究过程中选取的时间段较小，且实际中因水土流失而失去的有机碳可忽略不计，因此土壤中的有机碳 SOC 消耗量与植被数量相关，令植被吸收有机碳的影响因子为 k_1 ，则联合问题一的植被生物量演变模型可将 $C_{t\text{消}}$ 建模为：

$$C_{t\text{消}} = k_1 w_{tn} = k_1 (w_0 + \sum_{i=2}^n \int_{i-1}^i v_{i-1} dt) \quad (34)$$

对于土壤有机碳 SOC 的吸收量，根据参考文献得知土壤中的有机碳 SOC 主要是由植被自然枯萎转化和放牧时畜牧排出的排泄物转化两部分组成的。令枯萎转化因子为 k_2 ，则结合土壤含水量-降水量-地表蒸发模型中的枯萎率方程 $D = \beta * (e^{\varepsilon_s w / w^*} - 1)$ 可将植被自然枯萎转化的有机碳 C_1 建模为：

$$C_1 = k_2 D_{tn} w_{tn} = k_2 \beta (e^{\varepsilon_s w_{tn} / w^*} - 1) (w_0 + \sum_{i=2}^n \int_{i-1}^i v_{i-1} dt) \quad (35)$$

由题意知家畜日食量为 1.8kg，令放牧过程中畜牧的代谢因子为 α ，排泄物转化因子为 k_3 ，则放牧时畜牧排出的排泄物转化有机碳 C_2 建模为：

$$C_2 = k_3 \sum_{i=2}^n \int_{i-1}^i 1.8 \alpha dt \quad (36)$$

综上可得土壤有机碳 SOC 的吸收量 $C_{t\text{吸}}$ ：

$$C_{t吸} = C_1 + C_2 = k_2 \beta \left(e^{\frac{\varepsilon g w_{tn}}{w}} \right) \left(w_0 + \sum_{i=2}^n \int_{i-1}^i v_{i-1} dt \right) + k_3 \sum_{i=2}^n \int_{i-1}^i 1.8 \alpha dt \quad (37)$$

最终得到土壤有机碳 C_t 的机理模型为：

$$C_t = C_{t-1} + k_3 \sum_{i=2}^n \int_{i-1}^i 1.8 \alpha dt + k_2 D_{tn} \left(w_0 + \sum_{i=2}^n \int_{i-1}^i v_{i-1} dt \right) - a \quad (38)$$

$$a = k_1 (w_0 + \sum_{i=2}^n \int_{i-1}^i v_{i-1} dt) \quad (39)$$

式中，当 $t = 0$ 时， C_0 为土壤有机碳 SOC 的初始值。

2) 土壤无机碳 SIC

土壤无机碳主要是指土壤中各种负价态的含碳无机化合物，主要由土壤表面植被数量影响，当植被数量增大时，无机盐的成分降低，有利于防止土壤发生钙化。通过参考文献，令土壤钙化因子为 k_4 ，则土壤无机碳 C'_t 的机理模型为：

$$C'_t = k_4 C'_0 e^{-w_{tn}} \quad (40)$$

式中，当 $t = 0$ 时， C'_0 为土壤无机碳 SIC 的初始值。

3) 土壤全氮 N

通过参考文献得知，土壤中的含氮量取决于土壤中的有机物质，令土壤中的有机物质为 p_t ，有机物质转化率为 k_5 ，则结合土壤有机碳 C_t 的机理模型可建模为：

$$p_t = k_5 C_t \quad (41)$$

式中，资料显示 k_5 的值取 1.724，根据以上分析可将土壤全氮 N_t 的机理模型建模为：

$$N_t = a p_t + b \quad (42)$$

式中， a 、 b 均为常数。

4) 土壤全碳 STC

土壤全碳 STC 的含量为土壤有机碳 SOC 与土壤无机碳 SIC 之和。

5) 土壤 C/N 比

土壤 C/N 比的含量为土壤全碳 STC 与土壤全氮 N 之比。

6.3 土壤化学性质机理模型的求解

6.3.1 数据分布观察与可视化

首先，根据题意对附件 14 中的数据用与问题二相同的流程数据预处理，由于数据质量较好，仍然保留原始附件数据。为了获取待预测的土壤化学性质特征的大概信息，将数据按照相同年份所有地区进行平均，得到如下的土壤化学性质随年份变化图。可以看到，'SOC 土壤有机碳','全氮 N'这两个特征随年份有上升趋势。而 'SIC 土壤无机碳','STC 土壤全碳','土壤 C/N'比这三个特征随年份则有下降趋势。




图 30 土壤化学性质数据观测图

由于数据具有较好的规律性，简单高效的模型更适合本问题的求解，同时数据具有长期信息，为避免信息在模型训练过程中被遗忘，因此采用门控循环神经网络（GRU）^[5]。

6.3.2 门控循环神经网络（GRU）介绍

GRU(Gate Recurrent Unit)是循环神经网络的一种。和 LSTM(Long-Short Term Memory)一样，也是为了解决长期记忆和反向传播中的梯度等问题而提出来的。GRU 拥有与 LSTM 相同的优点，同时由于 GRU 减少了参数量，效率更高，适用于问题三待预测变量较多的复杂情况。




图 31 GRU 模型结构图

GRU 的内部结构如上图所示。通过上一个传输下来的状态 H_{t-1} 和当前输入 x_t 来获取两个门控状态。重置门为 $r_t = \sigma(x_t W_{xr} + H_{t-1} W_{hr} + b_r)$ ，更新门为 $u_t = \sigma(x_t W_{xu} + H_{t-1} W_{hu} + b_u)$ (σ 为 sigmoid 函数，通过这个函数可以将数据变换为 0-1 范围内的数值，从而来充当门控信号。) 重置门决定了如何将新的输入信息与前面的记忆相结合，更新门定义了前面记忆保存到当前时间步的量。

接下来，控循环单元将计算候选隐藏状态来辅助稍后的隐藏状态计算。如果重置门元素值接近 0，那么意味着重置对应隐藏状态元素为 0，即丢弃上一时间步的隐藏状态。如果元素值接近 1，那么表示保留上一时间步的隐藏状态。然后，将按元素乘法的结果与当前时间步的输出连结，再通过含激活函数 $\tanh$ 的全连接层计算出候选隐藏状态，其所有元素的值域为 $[-1,1]$ 。具体来说，时间步 t 的候选隐藏状态的计算为：

$$\tilde{H}_t = \tanh(X_t W_{xh} + (R_t \cdot H_{t-1}) W_{hh} + b_h) \quad (43)$$

从上述公式可以看出，重置门控制了上一时间步的隐藏状态如何流向当前时间步的候选隐藏状态。而上一时间步的隐藏状态可能包含了时间序列截至上一时间步的全部历史信息。因此，重置门可以用来丢弃与预测相关的历史信息。由于 GRU 只有两个门，GRU 参数比 LSTM 少，所以容易收敛，更适用于本问题建模。

6.3.3 基于 GRU-FC 网络的土壤化学性质预测模型

本问题要求预测 2022 年在不同放牧小区和放牧强度下的土壤化学性质。把一种放牧小区加放牧强度的组合叫做一种放牧类型。观察附件 14 数据，发现共有 12 种放牧类型，存在相同年份、相同放牧小区且相同放牧强度的数据分成了不同行，因此需要将相同年份、相同放牧小区且相同放牧强度的数据合并后求其平均值。结合之前问题一和问题二中放牧强度和放牧小区所引起的差异性，因此分别对不同放牧强度和不同放牧小区的共 12 个放牧类型分别建立其对土壤化学性质的影响预测模型，模型说明情况如下图所示。




图 32 土壤化学性质预测模型汇总图

模型结构上本问题的模型与问题二相似，不同的是这里采用了 GRU 模型，之后再接入全连接层预测最后输出。同时，由于数据更少，为了让模型获取更加全面有用的信

息，采用更大的隐藏层大小，即 512。综上建立的每个放牧类型的具体土壤化学性质模型结构以及中间维度变化如下图所示。




图 33 GRU-FC 模型结构图

训练网络过程中使用和问题二 LSTM 模型中相同的损失函数，即均方误差函数式：

$$MSE = (y_i - y'_i)^2 \quad (44)$$

式中： y_i 表示土壤某一及化学性质真实值， y'_i 表示土壤某一及化学性质预测值。

在模型对比方面，问题二在与其他模型的对比中 LSTM 取得了最优的效果，这里不再重复对比。在评价指标方面，由于采用和问题二相同的评价指标，这里不再赘述。

6.3.4 模型结果分析

1) GRU-FC 拟合结果图

使用网格搜索法，搜寻得到适用于土壤化学性质预测的最优超参数为：网络层数为 6 层、学习率为 0.001、批处理数为 1、迭代次数为 100，用最优的模型拟合数据结果。因为存在 12 中不同放牧类型的土地化学性质预测模型，这里每个放牧强度随机挑选一个放牧小区的预测模型做展示，土壤化学性质（'SOC 土壤有机碳'，'SIC 土壤无机碳'，'STC 土壤全碳'，'全氮 N'，'土壤 C-N 比'）五种特征的拟合效果如下图所示。




图 34 NG-G17 的五个土壤化学性质特征预测结果比较图




图 35 LGI-G6 的五个土壤化学性质特征预测结果比较图




图 36 MGI-G8 的五个土壤化学性质特征预测结果比较图



图 37 HGI-G9 的五个土壤化学性质特征预测结果比较图

3) 指标结果对比

为了验证 GRU-FC 对于土地化学性质特征预测的合理性和准确性，用 RMSE、MAE 以及 R2 这三个指标进行结果检验，由于有 12 个放牧类型的组合，每一个组合都要预测五种土地化学性质特征，因此对所有的 60 个指标（12*5）求均值结果如下表所示：

表 11 模型指标结果比较表

模型类型	RMSE	MAE	拟合度 R2
GRU-FC	0.2905	0.2510	0.9267

从表格结果，可以得出如下结论：（1）模型指标整体较好，RMSE 和 MAE 这两项损失下降到较小值，而拟合度 R2 达到了较高值。采用 GRU-FC 预测土壤化学性质是可靠的，精度比较高。（2）RMSE 的损失稍微高于 MAE，这是因为数据样本少，模型仍需要更多数据来

获得更好的拟合预测能力（3）拟合度并没有达到极高的值，这样能有效避免模型过拟合，体现出了 GRU 在数据较少时训练的模型优势。

6.3.5 模型对 2022 年土壤化学性质预测结果

根据 GRU-FC 模型预测未来 4 种放牧强度下的 12 个不同小区的'SOC 土壤有机碳'，'SIC 土壤无机碳'，'STC 土壤全碳'，'全氮 N'，'土壤 C-N 比'五个特征值，如下表所示：

表 12 土壤化学性质预测结果汇总表

放牧强度	Plot 放牧小区	SOC 土壤有机碳	SIC 土壤无机碳	STC 土壤全碳	全 N	土壤 C/N 比
NG	G17	16.66	5.09	21.75	2.07	10.51
	G19	15.05	6.03	21.08	1.94	10.87
	G21	20.74	3.51	24.25	2.76	8.79
LGI	G6	14.57	4.00	18.57	1.95	9.52
	G12	14.98	4.09	19.07	1.86	10.25
	G18	19.27	7.70	26.97	2.23	12.09
MGI	G8	14.30	3.42	17.72	1.93	9.18
	G11	13.88	4.67	18.55	1.82	10.19
	G16	14.83	9.10	23.93	1.58	15.15
HGI	G9	18.38	4.03	22.41	2.47	9.07
	G13	18.52	4.58	23.10	2.23	10.36
	G20	15.40	5.50	20.90	2.00	10.45

七、问题四的求解：放牧策略模型

7.1 问题分析

问题四可以分为三部分，第一部分是沙漠化程度指数预测模型的建立；第二部分是土壤板结化模型的建立，第三部分是结合以上两模型来最小化沙漠化程度指数与板结化程度，得到相应的放牧策略。

针对第一部分，通过查阅资料得到收集监测区域影响沙漠化指数的各因素的数据，利用层次分析法获取影响因子权重，根据预测数据和真实数据修正模型参数，得到沙漠化程度指数预测模型，最后进行模型参数检验。

针对第二部分，首先根据题意得知影响土壤板结程度的主要因素是土壤湿度 W 、容重 C 和有机物含量 O ，分别由参考文献得到容重数据、问题一土壤湿度机理模型得到土壤湿度数据、问题三土壤化学性质机理模型得到有机物含量数据，使用熵权法得到影响因子权重并检验，进而得到监测点的土壤板结化程度模型。

针对第三部分，结合以上的沙漠化指数模型和土壤板结程度，带入不同放牧策略下的

相关数据，得到相应的沙漠化指数和土壤板结化程度，通过最小化两者的加权和并进行合理性分析，得到应选取的放牧策略。综上，问题四的思路流程图如下所示：




图 38 问题四思路流程图

7.2 沙漠化程度指数预测模型的建立

7.2.1 沙漠化程度指数预测模型分析

根据参考文献[1]，沙漠化预测模型完整表达式

$$SM = \eta \cdot \sum_{i=1}^n (Q_i \cdot W_{c_i}) \tag{45}$$

Q 代表因子集合，W 代表因子权重集合，SM 代表沙漠化程度指数，η 为调节因子。本题需要确定因子强度，因子强度的权重，调节因子，最后需要检验模型正确性。

7.2.2 获取因子强度集合

因子强度有指标因子归一化得到，因此需要确定影响沙漠预测模型的指标因子，通过参考文献以及本题分析，将指标因子分为气候因素、地表因素和人文因素，分别包含风速、降水量、气温、植被覆盖度、土壤 10cm 湿度、畜牧数以及人均家庭经营纯收入^[7]，其中畜牧数和 10cm 湿度和人均家庭经营纯收入数据源自 2021 年锡林郭勒统计年鉴，其他都来自题目数据，指标因子与沙漠化程度关系具体如下图所示：




图 39 沙漠化程度影响指标体系图

对于任意一个指标因子，其发展程度的不同决定了对沙漠化的影响程度不同，即对沙漠化作用强度不同，其取值范围为[0, 1]，因子强度具体计算公式如下所示：

$$Q_i=(C_i-X_i)/(X_j-X_i) \tag{46}$$

其中 X_i 和 X_j 分别为指标因子的上下界。文中对于指标因子的上下界确定参考文献中设定，具体如下表所示。

表 13 指标因子上下界限表

指标因子	上限	下限
风速(m/s)	2.61	1.43
气温(°C)	35	5
降水量(mm)	100	10
植被覆盖度	50	10
土壤 10cm 湿度	22.1	9.97
畜牧数	8	0
人均家庭经营纯收入(元)	18864	8873

其中，降水量、植被覆盖度与土壤 10cm 湿度与沙漠呈反比关系，因此在计算因子强度分别如下：

$$Q_i = (X_j - C_i) / (X_j - X_i) \quad (47)$$

利用上述公式，计算 6 个指标因子对应的因子强度，如果不在范围之内，对于风速、气温、畜牧数以及人均家庭经营纯收入，低于下限设为 0，高于上限设为 1；对于降水量、植被覆盖度、土壤 10cm 湿度，低于下限设为 1，该与上限设为 0。

7.3 沙漠化程度指数预测模型的求解与检验

7.3.1 因子权重的计算

因子权重的确定过程比较复杂，目前常用的方法有层次分析法和主要成分法，由于植被覆盖度缺乏长期连续观测数据，因此问题四不太适合 PCA 方法，本文利用 AHP^[6]计算各个指标因子对应的权重，具体过程如下：

1) 构造判断矩阵

采用标度为 1~9 构造指标因子间的重要性判断矩阵，结合参考文献和地质专业高年级博士生意见，最终获得判断矩阵如表 1~3。

2) 计算因子权重

指标因子与沙漠化程度指数间存在三层影响关系，因子每个权重代表上层传递给下层的影响权重，对于判断矩阵的计算结果如表 1~3。计算流程为，计算判断矩阵的最大特征 $\lambda_{\max}$ 和特征向量 W，最后将 W 归一化即为权重。

$$w_i = \frac{\bar{w}_i}{\sum_{j=1}^n \bar{w}_j} (i=1,2,\dots,n) \quad (48)$$

3) 一致性检验

一致性检验用来衡量判断矩阵的不一致程度指标，是整个判断矩阵优化过程中必不可少的方法，本文利用 CI 修正后的 CR 作为一致性检验指标。当 $CR \leq 0.1$ 时认为判断矩阵得到可以接受的一致性，否则更新判断矩阵，计算如下所示：

$$CI = (\lambda_{\max} - n) / (n - 1) \quad (49)$$

$$CR = CI / RI \quad (50)$$

式中 n 是判断矩阵的维度， $\lambda_{\max}$ 为判断矩阵的最大特征根，RI 为随机一致性指标，本文中 $n=3$ ， $RI=1.6064$ ，计算判断矩阵的 CI 和 CR 的值如表 1~3 所示，其中 CR 都小于 0.1，通过一致性检验，表中的 W 为指示因子权重。

1) 气候因素、地表因素、人文因素层 AHP 分析

B 层因子 AHP 构造矩阵表

A	B1	B2	B3
B1	1.000	1.000	1.000
B2	1.000	1.000	1.250
B3	1.000	0.800	1.000

B 层因子 AHP 层次分析结果表

A	B1	B2	B3	CI 值
B1	0.998	33.272%		
B2	1.075	35.836%	3.006	0.003
B3	0.927	30.891%		

B 层因子一致性检验结果汇总表

最大特征根	CI 值	RI 值	CR 值	一致性检验结果
3.006	0.003	0.520	0.005	通过




图 40 B 层三个指标权重展示图

2) 气候因素下三个指标 AHP 分析结果

气候因子 AHP 构造矩阵表

	C1	C2	C3
C1	1.000	2.000	3.333
C2	0.500	1.000	1.250
C3	0.300	0.800	1.000

气候因子 AHP 层次分析结果表

项	特征向量	权重值	最大特征值	CI 值
C1	1.679	55.963%	3.009	0.005
C2	0.765	25.494%		
C3	0.556	18.543%		

表 1 气候因子一致性检验结果汇总表

最大特征根	CI 值	RI 值	CR 值	一致性检验结果
3.009	0.005	0.520	0.009	通过




图 41 B 气候因子指标权重展示图

3) 地表和人文下 4 个指标 AHP 分析结果

地表因子指标 AHP 构造矩阵表

	C4	C5
C4	1.000	2.000
C5	0.500	1.000

表 1 地表因子指标 AHP 层次分析结果表

项	特征向量	权重值	最大特征值	CI 值
C4	1.333	66.667%	2.000	0.000
C5	0.667	33.333%		

表 1 人文因子指标数据表

	C6	C7
C6	1.000	0.667
C7	1.500	1.000

表 1 人文因子 AHP 层次分析结果表

项	特征向量	权重值	最大特征值	CI 值
C6	0.800	40.000%	2.000	0.000
C7	1.200	60.000%		

通过以上各层的 AHP 分析结果可以看出，B 层和气候因素下的 CR 数值都小于 0.1，地表因素和人文因素下的 CR 为 0，因此都通过检验。最后对权重合成，得到 C 层 7 个指标因子权重如下表：

表 14 模型参数权重合成表

权重系数 WA	影响因素 Bi	权重系数 WBi	指标因子 Ci	权重系数 Wci
沙漠 化预 警指 标体 系 A	气象因素 B1	0.3327	风速 C1	0.1861
			气温 C2	0.0848
			降水量 C3	0.0617
	地表因子 B2	0.3584	植被覆盖度 C4	0.2389
			土壤 10cm 湿度 C5	0.1194
			畜牧数 C6	0.1235
	人文因子 B3	0.3089	人均家庭经营 纯收入 C7	0.1853

7.3.2 模型参数修正

模型中的指标因子和权重都已经得到，接下来需要调节 η ，使得模型计算的锡林郭勒沙漠化程度指数尽可能附合实际的沙漠化程度分布，达到精确的目的。




图 42（115.375，44.125）坐标位置图

表 15 国际沙漠划分程度分数表

划分内容	划分类型				
沙漠化程度	非沙漠化	轻度沙漠化	中度沙漠化	重度沙漠化	极重沙漠化
沙漠化程度指数	[0, 0.20]	(0.20, 0.40]	(0.40, 0.60]	(0.60, 0.80]	(0.80, 1.00]

根据经度 115.375 纬度 44.125, 该地区紧挨巴彦呼热乃巴润希勒, 通过国际沙漠划分程度判断属于轻度沙漠化地区, 分数应该在 $[0.2, 0.4]$ 之间。采用该地区 18 年 12 月的数据对参数 η 修正, 然后利用 19 年 12 月的数据对其进行检验。

表 16 参数修正前后表

时间	修正前模型 预测结果	修正前模型 预测结果	修正公式
18 年 12 月	0.7707	0.3584	$y = 0.4484 * x$
19 年 12 月	0.7466	0.3472	

从表 1 可以看到, 设定 $\eta = 0.4651$, 18 年 12 月预测结果修正后处于轻度沙漠化地区, 用 19 年 12 月数据验证, 同样在轻度沙漠化地区, 相邻年的沙漠化程度相似, 因此验证修正参数合理, 最终得到模型如下:

$$SM = 0.4484 \cdot \sum_{i=1}^7 (Q_i \cdot W_{c_i}) \quad (51)$$

$$W_1 = 0.1861, W_2 = 0.0848, W_3 = 0.0617, W_4 = 0.2389, W_5 = 0.1194, W_6 = 0.1235, W_7 = 0.1853 \quad (52)$$

7.3.3 模型准确性验证

将收集的 2012 年到 2019 年数据带入上述模型, 即实现沙漠化程度指数计算, 对照国际沙漠划分程度分数表获取沙漠化程度划分, 与真实划分相比, 计算准确率达为 87.5%, 由此验证模型准确。

7.4 土壤板结化模型的建立

7.4.1 土壤板结化定义

由题意知土壤板结化是指土壤打破了原有结构, 表层的有机质遭到严重破坏而造成的, 它与土壤有机物、土壤湿度和土壤的容重有关, 其数学模型可定性描述为如下:

$$B = f(W, C, O) \quad (53)$$

式中, 土壤湿度 W 越少, 容重 C 越大, 有机物含量 O 越低, 土壤板结化程度 B 越严重。分别令土壤湿度、容重和有机物含量的权重为 k_1, k_2, k_3 , 令调节因子为 k_4 , 得到土壤板结化程度量化模型为:

$$B = k_1 W + k_2 C + k_3 O + k_4 \quad (54)$$

7.4.2 土壤板结化指标评价模型

根据题目要求，使用熵权法对土壤板结化模型进行权重量化，熵权法计算土壤板结化模型权重的原理如下：

1) 可利用信息熵的概念确定权重，假设多属性决策矩阵如下：

$$M = \begin{matrix} & \begin{matrix} A_1 & A_2 & \cdots & A_n \end{matrix} \\ \begin{matrix} x_{11} & x_{12} & \cdots & x_{1m} \\ x_{21} & x_{22} & \cdots & x_{2m} \\ \vdots & \vdots & \ddots & \vdots \\ x_{n1} & x_{n2} & \cdots & x_{nm} \end{matrix} \end{matrix} \quad (55)$$

则用 $P_{ij} = \frac{x_{ij}}{\sum_{i=1}^n x_{ij}}$ 表示第 j 个属性下第 i 个方案 A_i 的贡献度。

2) 可以用 E_j 来表示所有方案对属性 X_j 的总贡献度：

$$E_j = -K \sum_{i=1}^n P_{ij} \ln P_{ij} \quad (56)$$

其中，常数 $K = \frac{1}{\ln(n)}$ ，保证 $0 \leq E_j \leq 1$ ，即 E_j 最大 1。

3) 可以看出属性的权重系数大小由各方案差异大小来决定，为此可定义 d_j 为第 j 属性的各方案贡献度的一致性程度：

$$d_j = 1 - E_j \quad (57)$$

4) 进行归一化后，各属性权重如下：

$$W_j = \frac{d_j}{\sum_{j=1}^m d_j} \quad (58)$$

当 $d_j = 0$ 时，第 j 属性可以剔除，其权重等于 0。

7.5 土壤板结化模型的求解与检验

采用附件中的相关数据带入问题一的土壤湿度演变模型得到监测区域在不同放牧强度下的土壤湿度数据，查阅相关文献选用 10cm 土壤湿度作为影响土壤板结化的因素；由问题三的分析可使用监测区域土壤的有机碳含量衡量土壤的有机物含量，因此使用问题三的土壤化学性质预测模型得到监测区域在不同放牧强度下的有机碳含量作为影响土壤板

结化的因素；搜集参考文献可得监测区域不同放牧强度下的容重数据（如下表），统一使用平地地形容重的平均值来作为影响土壤板结化的因素。

表 17 不同条件下土壤容重统计特征值表

土地利用	地形	观测数	最小值/ (g·cm ⁻³)	最大值/ (g·cm ⁻³)	平均值/ (g·cm ⁻³)
禁牧	迎风坡	-	-	-	-
	背风坡	2	1.09	1.19	1.14
	平地	2	1.09	1.17	1.13
轻牧	迎风坡	5	1.11	1.28	1.20
	背风坡	8	1.02	1.22	1.16
	平地	3	1.03	1.23	1.15
中牧	迎风坡	26	0.93	1.24	1.12
	背风坡	40	1.01	1.34	1.18
	平地	16	0.99	1.43	1.27
重牧	迎风坡	8	1.07	1.33	1.21
	背风坡	23	1.14	1.47	1.30
	平地	11	1.21	1.43	1.32

将处理整合后的数据带入所建立的土壤板结化指标评价模型中，可以解得土壤板结化程度模型为：

$$B = -0.72W + 0.47C - 0.54O + 1.3 \tag{59}$$

式中，土壤湿度、容重和有机物的权重和调节常数 k_1, k_2, k_3, k_4 的值分别为-0.72、0.47、-0.54、1.3，因此土壤板结化程度与土壤湿度和有机物含量成负相关，与土壤的容重成正相关，这符合土壤板结化的定性描述。且相关程度土壤湿度>有机物含量>土壤容重，综上可以检验土壤板结化程度模型的合理性与正确性。

将监测区域在不同放牧强度下的整合数据带入以上模型中可以得到不同放牧强度下的土壤板结化程度分数，结果如下表所示：

表 18 监测区域不同放牧强度下的土壤板结化程度分数表

放牧强度	禁牧	轻牧	中牧	重牧
土壤板结化程度分数	0.62	0.73	1.01	1.15

查阅相关文献，根据分析制定量化土壤板结化程度划分分数表如下：

表 19 土壤板结化程度划分分数表

划分内容	划分类型			
土壤板结化程度	非板结化	轻度板结化	中度板结化	重度板结化
土壤板结化程度分数	[0, 0.70]	(0.70, 1.00]	(1.00, 1.30]	(1.30, 1.50]

7.6 放牧策略模型的建立与求解

为求解使得沙漠化程度指数与板结化程度最小的放牧策略，综合以上的沙漠化程度指数预测模型和土壤板结化模型，建立放牧策略模型如下：

$$M = SM + \alpha B \tag{60}$$

式中， M 为环境影响指数，值为沙漠化程度指数与板结化程度指数的加权和， α 为调节系数，取值为 0.67。

将监测区域在不同放牧强度下的整合数据带入放牧策略模型中可以得到不同放牧强度下的沙漠化程度指数与土壤板结化程度分数之和，结果如下表所示：

表 20 监测区域不同放牧强度下的沙漠化程度与土壤板结化程度分数之和表

放牧强度	禁牧	轻牧	中牧	重牧
环境影响指数	0.72	0.80	1.01	1.53
相对程度变化	-	0.08	0.21	0.52
环境影响程度	低	低	中	高

从结果中可以看出，随着放牧强度的增加，沙漠化程度指数和土壤板结化程度之和依次递增，每种放牧强度相对前一种来说使得土壤沙漠化与板结化程度分数的相对变化分别为 0.08， 0.21， 0.52，因此可以将放牧对环境影响程度分为三类，程度最低的为禁牧和轻牧，其次为中牧，最高的为重牧。

对于环境影响来考虑，可以选择禁牧和轻牧的牧羊策略，综合考虑到牧羊带来的经济效益，选择轻牧作为最终的牧羊策略。

八、问题五的求解：最大放牧羊群优化模型

8.1 问题分析

针对问题五，要求给定的降水量（300mm，600mm、900 mm 和 1200mm）情形下，在保持草原可持续发展情况下对实验草场内放牧羊的数量进行求解，找到最大阈值。根据题意得知可持续发展的定义是：“可持续发展是经济规模增长没有超越生物环境承载能力的发展”。一方面，生物环境承载能力可使用问题四中的沙漠化程度和板结化程度衡量，当土壤的沙漠化程度和板结化程度达到阈值即为达到该地的生物环境承载能力。另一方面，

经济规模可使用草场内放牧羊的数量衡量，放牧羊的数量越大，其经济规模越大。综上，要保证可持续发展即为提高放牧羊的数量的同时保证不超出本地的沙漠化程度和板结化程度阈值，因此可以将最大放牧羊群优化模型建模为以土壤沙漠化程度与土壤板结化程度为约束，在给定的各降水量情形下，最大化实验草场内的放牧羊数量的线性规划模型。

模型求解方面，考虑采用一种广泛用于优化问题的粒子群算法对该问题进行求解，并针对算法中的惯性因子等参数进行优化得到搜索能力更强、精度更高的基于分子运动论的遗传粒子群优化算法 GA-MPSO，使得算法与问题的契合度更高。然后对上述线性规划模型进行求解，得到给定的降水量情形下的最大放牧羊的数量。最后，为了验证 GA-MPSO 算法的有效性与优越性，将其与改进前的两种优化算法进行对比。问题五的思路流程图如下：




图 43 问题五的思路流程图

8.2 最大放牧羊群线性规划模型建立

(1) 目标函数

针对该问题，确定线性规划模型的目标函数为最大化实验草场内的放牧羊的数量，其表达式如下所示：

$$\max S \quad (61)$$

其中， S 为放牧强度，即单位面积牲畜数量。

(2) 决策变量

该线性规划模型的决策变量为 9 个环境因子 $x_i (i = 1, 2, \dots, 9)$ ，其中影响土壤沙漠化程度的因子有 7 个（风速、降水量、气温、植被覆盖度、土壤 10cm 湿度、畜牧数以及人均家庭经营纯收入）、影响土壤板结化的因子有 3 个（土壤湿度、容重和有机物含量，其中土壤湿度为共同因子），其每一组取值表示相应一种环境方案。

(3) 土壤沙漠化程度与土壤板结化程度约束

根据题目要求，为保持草原可持续发展，应使得土壤沙漠化程度与土壤板结化程度在合适的范围内，根据参考文献得到它们的阈值，构建关于土壤沙漠化程度与土壤板结化程度约束条件如下所示：

$$SM \leq threshold_1 \quad (62)$$

$$B \leq threshold_2 \quad (63)$$

其中， SM 、 B 分别为土壤沙漠化程度与土壤板结化程度， $threshold_1$ 、 $threshold_2$ 分别为两者的阈值，取值分别为 0.4 和 0.6。优化环境因子之后土壤沙漠化程度与土壤板结化程度的计算公式已由问题四求出，使用 f_{SM} 表示土壤沙漠化指数预测模型、 f_B 表示土壤板结化模型，其表示如下所示：

$$SM = f_{SM}(x_1, x_2, \dots, x_7) \quad (64)$$

$$B = f_B(x_5, x_8, x_9) \quad (65)$$

其中 $x_1, x_2, \dots, x_7$ 分别表示环境因子风速、降水量、气温、植被覆盖度、土壤 10cm 湿度、畜牧数以及人均家庭经营纯收入， x_5, x_8, x_9 分别表示环境因子土壤湿度、容重和有机物含量。

(4) 各环境因子取值约束

根据附件提供的数据以及自己收集的数据，确定各环境因子的取值范围，构建各环境因子取值约束，如下所示：

$$x_{i \min} \leq x_i \leq x_{i \max} \quad (66)$$

其中, $x_{i \min}$ 表示各环境因子可取到的最小值, $x_{i \max}$ 表示各环境因子可取到的最大值。

(5) 降水量约束

根据题意, 需要在给定的年降水量 (300mm, 600mm、900 mm 和 1200mm) 情形下, 分别求解目标函数的极值, 由于之前建立的相关模型采用的为月降水量, 因此对年降水量求均值得到月降水量 (25mm, 50mm、75 mm 和 100mm), 所构建的降水量 x_2 约束如下:

$$x_2 = 25, 50, 75, 100 \quad (67)$$

(6) 综合模型

综上所述, 针对问题四建立如下的最大放牧羊群线性规划模型:

$$\max S \quad (68)$$

$$s. t. \begin{cases} SM \leq threshold_1 \\ B \leq threshold_2 \\ SM = f_{SM}(x_1, x_2, \dots, x_7) \\ B = f_B(x_5, x_8, x_9) \\ x_{i \min} \leq x_i \leq x_{i \max} \\ x_2 = 25, 50, 75, 100 \\ i = 1, 2, \dots, 9 \end{cases} \quad (69)$$

8.3 模型求解

针对上述线性规划模型, 使用粒子群算法进行优化, 并且使用基于分子运动论的粒子群优化算法 (MPSO) 和遗传粒子群融合算法 (GA-PSO) 进行改进得到基于分子运动论的遗传粒子群优化算法 (GA-MPSO), 最后将三个算法的求解结果进行对比, 以证明本文所改进的算法方案的优势。

8.3.1 粒子群算法 (PSO)

粒子群优化算法是一种基于群智能方法的演化计算技术, 它最初由 Kennedy 和 Ebert 从模拟鸟类的飞行的行为而起来的[11-12]。在 D 维的搜索空间中, 有随机分布的 m 个粒子组成的一个初始粒子群, 每个粒子有各自的位置和速度。如第 i 个粒子的位置表示为一个 D 维的向量, 记为 $\vec{x}_i = (x_{i1}, x_{i2}, \dots, x_{iD})$; 速度也是一个 D 维的向量, 记为 $\vec{v}_i = (v_{i1}, v_{i2}, \dots, v_{iD})$ 。每个粒子记住自己在迭代过程中找到的最优位置, 记为 $\vec{p}_i = (p_{i1}, p_{i2}, \dots, p_{iD})$, 整个粒子群迄今为止搜索到的最优位置为全局最优解, 记为 $\vec{p}_g = (p_{g1}, p_{g2}, \dots, p_{gD})$ 。PSO 算法将个体的更新转换为粒子在解空间的位置移动, 移动的方向由全局最优粒子的位置和个体所找到的最优位置所决定的。对解的更新加入了全局与局部最优信息, 位置的移动更有目的性, 算法有更好的收敛速度。关于 PSO 算法对粒子位置的更新, 是按下面的公式进行的:

$$V_i = \alpha V_i - c_1 r_1 (P_i - X_i) + c_2 r_2 (P_g - X_i) \quad (70)$$

$$X_i = X_i + \beta V_i \quad (71)$$

其中, $i = 1, \dots, \text{popsize}$, popsize 是种群规模; V_i 表示当前粒子 i 的速度; X_i 表示当前粒子 i 的位置; P_i 表示粒子 i 迄今为止所搜索到的最优位置; P_g 表示整个粒子群迄今为止所搜索的最优位置; 学习因子 c_1, c_2 为非负常数; r_1, r_2 为介于 $[0, 1]$ 之间的随机数; α 为惯性因子; β 为速度控制约束因子。

粒子群优化算法的流程图可总结如下:




图 44 粒子群优化算法流程图

8.3.2 基于分子运动论的粒子群优化算法 (MPSO)

MPSO 是受粒子动力学演化算法启发把统计物理中的分子运动论引入到基本粒子群优化算法中来设计一种新颖的粒子群优化算法, 算法中的粒子除了具有速度和位置属性之外, 还增加了一个加速度属性, 算法中还定义了群质心的概念。

群质心指种群所有粒子的质量集中于此的一个假想点。在一个 N 维空间中, 群质心计算公式为

$$X_{cen} = \frac{\sum_{i=1}^N X_i m_i}{\sum_{i=1}^N m_i} \quad (72)$$

其中， X_i 表示种群中粒子 i 的坐标； m_i 表示种群中粒子 i 的质量，可以把 m_i 看成是粒子 i 的权重，实际处理时可以令 m_i 等于粒子 i 的适应值，在本章中假设各粒子的质量相等且为1，以上公式简化为：

$$X_{cen} = \frac{\sum_{i=1}^N X_i}{N} \quad (73)$$

定义 1 由于分子间距离的变化，当 F 在斥力和引力之间转换时， F 的大小和方向也会随之变化，根据牛顿第二定律：

$$a = F / m \quad (74)$$

加速度 a 的大小和方向也会随之改变。忽略 a 的大小，只考虑它的方向，当分子力 F 呈现为引力时 $a = 1$ ，当分子力 F 呈现为斥力时 $a = -1$ 。

根据定义 1 重新定义了粒子的速度更新公式，此时公式变更为

$$v_{id}^{t+1} = \omega v_{id}^t + a_i [R_1 c_1 (p_{id} - x_{id}^t) + R_2 c_2 (p_{gd} - x_{id}^t)] \quad (75)$$

其中， a_i 表示粒子 i 的加速度，初始化时所有粒子的加速度 a_i 都默认设置为 1。

根据以上的分析和定义，可以发现分子的热运动和 MPSO 算法之间有诸多相似之处，它们之间的对应关系如表所示。

表 21 MPSO 算法与分子运动论的相似关系表

MPSO 算法	分子运动论
种群	分子系统
粒子	分子
吸引状态	分子间的引力
排斥状态	分子间的斥力
粒子的加速度	分子的加速度
群质心	分子系统的重心

MPSO 算法的流程如下。

Step1: 初始化种群粒子(群体规模为M)，包括位置、速度和加速度;
Step2: 根据适应度公式，计算每个粒子的适应值;
Step3: 对每个粒子，将其当前适应值与其个体历史最佳位置对应的适应值作比较，如果当前的适应值更高，则判断粒子的当前位置是否满足约束条件，如果满足则将用当前位置更新历史最佳位置，否则不进行更新;
Step4: 对每个粒子，将其前适应值与全局最佳位置对应的适应值作比较，如果当前的适应值更高，则将用当前位置更新全局最佳位置;
Step5: 根据公式更新每个粒子的速度与位置;
Step6: 判断是否满足结束条件，如未满足，则返回 Step2;
Step7: $for(i = 0; i < M; i++)$ { $if(a_i == 1 \ \&\& \ d(X_{cen}, X_i) < d_l)$ $a_i = -1$ $if(a_i == -1 \ \&\& \ d(X_{cen}, X_i) > d_l)$ $a_i = 1$ 调整粒子的速度和位置 }
Step8: 判断是否满足结束条件，如未满足，则返回 Step2; 否则，输出算法所找到的全局最优解，算法结束。

8.3.3 基于分子运动论的遗传粒子群优化算法 (GA-MPSO)

GA-MPSO 是综合了遗传算法 (GA) 和基于分子运动论的粒子群优化算法 (MPSO) 各优缺点的基础上，克服 GA 的局部最优并利用 MPSO 快速达到问题要求的精度。该算法的重点在于寻到恰当的结合点，充分发挥 GA 和 MPSO 的搜索能力，避免过早收敛，提升搜索的精度。GA-MPSO 算法的流程如下。

Step1: 初始化 GA 和 MPSO 的参数 (种群规模 $Popsiz$ e, 变异概率 P_m , 交叉概率 P_c 等), 对于惯性因子 α 对优化性能的影响, 较大的 α 利于跳出局部最优, 较小的 α 利于算法的收敛。在这里采用自适应调整, 即 $\alpha = \alpha_{max} - run \frac{\alpha_{max} - \alpha_{min}}{epoch} \quad (76)$ $\alpha_{max}, \alpha_{min}$ 分别代表最大最小惯性因子, 分别取 0.9 和 0.1, run 为当前的迭代次数。
Step2: 根据适应度公式，计算每个粒子的适应值；并按照 $V_i =$ 和 $X_i =$ 式进行更新产生种群 pop_1 。
Step3: 对种群 pop_1 中的各个体根据适应度公式进行评估，并采用轮盘赌选出染色体对，以概率 P_c 进行算术交叉操作，得到种群 pop' 。
Step4: 对种群 pop' 以概率 P_m 进行方向变异操作，产生新的种群 pop_2 ;
Step5: 从种群 pop_1 和种群 pop_2 中挑选精英产生下一代种群 pop'' ;
Step6: 若超过迭代次数或当前解中的最优个体的误差满足要求，则输出结果，否则返回 Step2;

8.3.4 模型参数设定

依据题目要求，选用基于分子运动论的遗传粒子群优化算法进行优化，由于环境因子的取值相差较大，因此使用归一化公式对数据进行归一化处理，则各环境因子的最大值和最小值均为 0 和 1。最后通过 Python 编程求解，结合相关因素，基于分子运动论的遗传粒子群算法的主要变量设定值如下表所示：

表 22 基于分子运动论的遗传粒子群优化算法参数设置表

参数名称	符号	值
种群大小	$Popsiz$	30
维数	D	9
惯性因子	α	0.8
学习因子	c_1, c_2	1.2
第 i 个粒子的速度范围	$[v_{min}^i, v_{max}^i]$	$[lower_i, upper_i]$
最大迭代步长	$step$	100
初始化各粒子的位置	x_0	随机数+专家经验
初始化各粒子的速度	v_0	随机数
目标函数的加权系数	λ_1, λ_2	0.7, 0.3

8.3.5 结果分析与可视化

在优化过程中，粒子刚开始无规律地分布在解空间中，然后逐渐找到附近的局部最优解，接着大多数粒子朝着全局最优解演化，最后大部分粒子都驻守在全局最优解，如下图。




图 45 粒子群演化过程图

在计算过程中，求解给定的降水量 300mm，600mm、900mm 和 1200mm 情形下的各样本适应度进化曲线如下图，可以看出模型避免过早收敛，提升了搜索的精度。




图 46 适应度进化曲线图

在演化过程中，求解给定的降水量 300mm，600mm、900mm 和 1200mm 情形下的各样本收敛时的迭代次数以及最优解（取相反数）见下表，平均最优值即放牧羊的平均最大阈值为 5.41，平均收敛次数为 61 次，并未超过预设参数，说明优化算法的参数设置是合理的，且求解性能高。

表 23 各降水量样本收敛时迭代次数和最优解表

降水量样本	收敛时迭代次数	收敛时最优解
300mm	48	3.91
600mm	72	4.56
900mm	68	6.03
1200mm	58	7.12

各降水量下的样本优化后的环境条件如下表所示：

表 24 样本优化后的环境条件表

降水量样本		优化后的环境条件					
300mm	1.43	22.93	48.59	22.10	9591.70	1.33	16.24
...				...			
1200mm	1.46	8.32	49	22.05	8909.07	1.10	16.33

8.4 模型对比

本文采用基于分子运动论的遗传粒子群优化算法 (GA-MPSO) 求解上述线性规划模型，并与粒子群优化算法 (PSO) 和基于分子运动论的粒子群优化算法 (MPSO) 求解效果进行对比分析。以求解 600mm 降水量时的最优阈值时的适应度进化为例，多次实验求平均得到其进化曲线对比图如下：




图 47 适应度进化曲线对比图

如上图对比分析可知，比起 PSO 算法和 MPSO 算法，基于 GA-MPSO 算法优化收敛时精度更高，更不容易陷入局部最优解；虽然 MPSO 算法收敛性能较强，但比起 GA-MPSO 求解全局最优的性能差一些。综上对比，改进的 GA-MPSO 和 MPSO 算法均起到了很好的效果，性能排序为 GA-MPSO>MPSO>PSO。

九、问题六的求解：牧户土地状态预测及演示

9.1 问题分析

根据问题六的要求，需要在牧户放牧策略不变和问题 4 中得到的放牧方案的两种情况下预测并演示这些示范牧户的土地状态（土壤肥力变化、土壤湿度、植被覆盖等）。换句

话说，需要获取当前示范牧户的放牧策略以及土地状态，从而利用模型预测出未来土地状态，同时结合问题 4 的放牧策略和牧户原有放牧策略进行比较，证明问题四结论的合理性。因此，解决问题的关键在于获取牧户的放牧策略信息和土地状态信息。

首先探索牧户土地的地理位置信息，由于牧户、试验样地和附件基本数据中的坐标离得很近，可以将试验样地和附件基本数据作为数据补充。

针对土壤肥力变化预测，为了结合前置问题的模型，根据牧户放牧方式以及牧户所在区域植物的干重之和与各个放牧小区的放牧强度以及植物的干重之和进行对比，将牧户所在区域等效于那个放牧强度和植物干重之和最相似的放牧小区。然后根据匹配的放牧小区的历史数据信息以及前置问题建立的土壤肥力变化模型进行本问题的土壤肥力变化预测。

针对土壤湿度预测，拟采用问题一中的土壤湿度机理模型，但其变量有放牧策略和降雨量等，而缺失未来的降雨量数据，因此首先根据牧户匹配的放牧小区的数据建立降雨量预测模型，在预测出未来的降雨量数据后，结合匹配的放牧小区的土壤状态初始值和放牧策略，最后进行土壤湿度预测。

针对植被覆盖预测，拟采用问题一中的植被生物量机理模型，结合匹配的放牧小区的植被生物量干重之和初始值和放牧策略，进行植被覆盖预测。

综上，问题六的思路流程图如下：




图 48 问题六的思路流程图

9.2 牧户地理位置分析

由题目可以得到，四个牧户的经纬度分别为，根据题目所提供的地图，可以发现他们都分布在典型草原类别上。同时根据题目所给实验放牧小区的附件数据介绍，试验样地设于内蒙古锡林浩特市东 20km 锡林浩特国家气候观象台生态监测样地，经查询，1 经度=111km，根据锡林浩特的经纬度，从而得到实验样地监测点的位置，即（116.25,43.93），基本数据里的经纬度为（115.375，44.125），四个牧户的平均坐标为（116.01，44.21），他们的位置关系如图所示。由于三个地点地理位置较近，所以牧户土地建模数据可以参考基本数据和监测点数据。



图 49 地理位置示意图

9.3 牧户与放牧小区的匹配

根据附件数据可以较为容易地获取牧户放牧强度的信息，并以此匹配具有相同放牧强度的放牧小区从而获取可用于牧户土地预测的数据。但是这种方法对于四个牧户都将获取到相同的土地状态初始值，由于不同牧户所在土地地理位置不同，土地状态信息应各不相同，这种方法考虑的并不完全。因此将土地的植被状态（用样方生物量干重之和表示）考虑进来，该特征可以较好地反映出不同牧户拥有土地的不同状态，从而根据放牧强度、样方生物量干重之和两个特征可以很好的找到最符合牧户当前状态的小区。可以发现牧户位置和试验样地位置接近，放牧小区的部分数据可以用于牧户的土壤状态模型预测。

9.3.1 牧户放牧强度匹配

根据附件数据“内蒙古自治区锡林郭勒盟不同示范牧户牲畜数量调查数据集（2018 年 7 月 28 日-2020 年 9 月 30 日）”中的“牲畜数量”表格可以获取到放牧压力（只羊/km²），将单位转换为“羊/天/公顷”并四舍五入后可以与对应的范围规定的放牧强度进行匹配，从而获取每个牧户的放牧强度，表格表示如下：

表 25 牧户放牧强度表

放牧强度	
牧户 1	中度放牧强度（MGI， 3 -4 羊/天/公顷）
牧户 2	轻度放牧强度（LGI， 1-2 羊/天/公顷）
牧户 3	重度放牧强度（HGI， 5-8 羊天/公顷）
牧户 4	轻度放牧强度（LGI， 1-2 羊/天/公顷）

9.3.2 牧户样方生物量干重之和匹配

根据附件数据“内蒙古自治区锡林郭勒盟不同牧户生态畜牧业模式群落样方调查数据集”及其数据说明可知，其中的数据是 2018 年 7 月-2020 年 9 月的生态畜牧业模式群落样方调查数据，对数据样方生物量干重求和得到每个牧户在每一年的样方生物量干重之和。同时，从“附件 15 群落结构监测数据集”中筛选出所有放牧小区在 2018 年 7 月-2020 年 9 月的生物量干重并求和。使牧户和放牧小区的放牧强度匹配的基础上，再比较四个牧户和不同放牧小区生物量干重之和，找到最匹配的那个放牧小区。由于牧户二和牧户四放牧强度都为轻牧，所以仅考虑牧户二。不同牧户和其放牧小区的生物量干重之和比较图如下：




图 50 牧户一与中牧放牧小区植物干重之和对比图




图 51 牧户二与轻牧放牧小区植物干重之和对比图




图 52 牧户三与重牧放牧小区植物干重之和对比图

综合上图可得牧户 1, 2, 3 对应的放牧小区分别是 G16,G18,G9,G18, 在牧户某项土地数据缺失时, 对应放牧小区的数据可以辅助补充。

9.4 牧户土壤肥力变化预测

9.4.1 土壤肥力变化预测分析

由于在问题三中得到了不同放牧小区的五种土壤化学性质预测模型, 而牧户的土壤化学性质数据缺失, 因此可以根据问题三中训练的模型, 以与牧户匹配的放牧小区的化学性质作为输入, 从而预测 2023 年的牧户土壤化学性质。由于存在采用轻牧放牧策略的牧户匹配的放牧小区, 可以看作问题四中的放牧方案, 与不采用轻牧的牧户进行比较。

需要注意的是放牧小区中的数据提供的是 2012-2020 年的偶数年的化学性质, 因此, 使用匹配放牧小区的 GRU-FC 预测模型预测出 2022 年的结果, 之后将其拼成 2012-2022 年的数据后作为输入, 从而预测 2024 年的数据, 再对 2022 年和 2024 年的预测结果取均值从而获取 2023 年土壤化学性质预测结果。

9.4.2 土壤肥力变化趋势预测

不同牧户土壤肥力变化趋势如图所示:




图 53 牧户一土壤肥力变化趋势观测图




图 54 牧户二土壤肥力变化趋势观测图




图 55 牧户三土壤肥力变化趋势观测图

从图中可以看出，由于牧户 2 和牧户 4 采用了轻牧的放牧策略，SOC 土壤有机碳和 STC 土壤全碳含量逐渐升高，而牧户 1 采用中牧的放牧策略，STC 土壤全碳含量基本持平，牧户 3 采用重牧的放牧策略，STC 土壤全碳含量呈现下降趋势。而 STC 土壤全碳含量可以反映出土壤肥力，因此采用轻牧放牧策略可以增加土壤肥力，这个结果印证了问题四中的结论。

9.4.3 土壤肥力变化预测结果

模型预测出的不同牧户 2023 年 9 月份土壤肥力特征结果如下：

表 26 土壤肥力特征预测结果表

	SOC 土壤有机碳	SIC 土壤无机碳	STC 土壤全碳	全氮 N	土壤 C-N 比
牧户 1	14.51	10.44	24.78	1.69	15.83
牧户 2	21.52	6.26	27.38	2.48	11.38
牧户 3	19.25	2.51	19.99	2.63	8.38
牧户 4	21.46	6.29	27.38	2.48	11.32

9.5 牧户土壤湿度预测

9.5.1 土壤湿度预测分析

通过经纬度坐标对比，发现坐标（115.375，44.125）与试验地极为相近，因此利用（115.375，44.125）的数据预测 2023 年 9 月的土壤湿度。利用第一问求解的土壤 200cm

湿度和降雨量、蒸发量和放牧强度的模型预测接下来 18 个月的土壤 200cm 湿度，第 18 个月即为预测结果。

由于未来 18 个月不存在降雨量和蒸发量数据，因此建模拟合降雨量和时间的关系，蒸发量和时间的关系，分别预测未来 18 个月降雨量和蒸发量，带入第一问公式即可。

9.5.2 ARIMA 时间序列预测模型

ARIMA 为自回归积分滑动平均模型，由 AR、I 和 MA 组成，其符号表示为 ARIMA (p,d,q)，为针对非平稳的时间序列的模型。

1) 自回归模型 AR

自回归模型利用自己的历史数据对自身未来时间预测，预测只能在满足平稳性要求下进行，平稳性检验利用 ADF 进行，AR 公式如下：

$$y_t = \mu + \varepsilon_t + \sum_{i=1}^p \gamma_i y_{t-i} \quad (77)$$

式中， y_t 表示当前值， μ 为常数， p 为阶数， γ_i 为自相关系数， ε_t 为误差。

2) 移动平均模型 MA

移动平均模型是为了消除自回归模型的随机波动，即为了消除随机误差，表达式如下：

$$y_t = \mu + \varepsilon_t + \sum_{i=1}^q \theta_i \varepsilon_{t-i} \quad (78)$$

3) 自回归移动平均模型 ARIMA

将回归模型和移动平均模型结合得到自回归移动平均模型，表达式如下：

$$y_t = \mu + \varepsilon_t + \sum_{i=1}^q \theta_i \varepsilon_{t-i} + \sum_{i=1}^p \gamma_i y_{t-i} \quad (79)$$

9.5.3 ARIMA 模型预测降雨量特征

统计附件 8 中的降雨量数据，对数据按照时间排序，得到 127 条随着时间变化的降雨量数据。利用 Python 和 SPSS 对数据建立 ARIMA 时间序列预测模型，预测未来 14 个月的降雨量。

首先进行平稳性检验，检验结果如下：

表 27 降雨量 ADF 检验表

变量	差分阶数	t	P	AIC	临界值		
					1%	5%	10%
降水量(mm)	0	-6.71	0.000***	1425.844	-3.483	-2.885	-2.579
	1	-6.994	0.000***	1420.811	-3.489	-2.887	-2.58
	2	-7.283	0.000***	1429.804	-3.49	-2.888	-2.581

注：***、**、*分别代表 1%、5%、10%的显著性水平

ACF 和 PACF 结果如下：



图 56 降雨量预测模型 ACF 检验结果图



图 57 降雨量预测模型 PACF 检验结果图

降雨量预测结果和拟合效果如下：




图 58 降雨量预测模型拟合和预测结果图

预测结果与之前变化趋势保持一致，预测效果较好。

9.5.4 ARIMA 模型预测蒸发量特征

统计附件 4 中的蒸发量数据，对数据按照时间排序，得到 123 条随着时间变化的蒸发量数据。利用 Python 和 SPSS 对数据建立 ARIMA 时间序列预测模型，预测未来 18 个月的降雨量。

表 28 蒸发量 ADF 检验表

变量	差分阶数	t	P	AIC	临界值		
					1%	5%	10%
土壤蒸发量(mm)	0	-1.505	0.531	642.55	-3.491	-2.888	-2.581
	1	-10.061	0.000***	637.908	-3.491	-2.888	-2.581
	2	-7.847	0.000***	656.918	-3.493	-2.889	-2.581

注：***、**、*分别代表 1%、5%、10%的显著性水平

ACF 和 PACF 结果如下：



图 59 蒸发量预测模型 ACF 验证图



图 60 蒸发量预测模型 PACF 验证图

蒸发量预测结果和模型拟合效果如下：




图 61 蒸发量预测模型拟合效果和预测结果图

预测结果保持原来变化趋势，预测效果较好。

9.5.6 土壤湿度模型预测变化趋势

通过 ARIMA 预测未来至 23 年 9 月的降雨量和蒸发量数据，利用问题一中建立的土壤 200cm 湿度预测模型预测土壤 200cm 湿度。

通过分析四户牧民的畜牧量得牧户的放牧策略有三种，分别为轻牧（牧户二，牧户四）、中牧（牧户一）和重牧（牧户三），因为问题四中最优策略为中牧包含在内，所以不在单独画图。分别将放牧强度设为 2，4，8 带入湿度预测模型，三种结果如下所示：




图 62 三个牧户土壤湿度预测图

三种放牧强度下，土壤湿度大小比较为轻牧>中牧>重牧，附合实际情况。

土壤湿度与沙漠化和板结化指数呈反比，这里中牧下的土壤湿度最高，沙漠化程度指数与板结化程度最小，进一步验证了问题 4 的结论。

9.5.7 土壤湿度模型预测结果展示

上图展示了 2023 年 9 月近一年的湿度变化趋势，下表详细记录了不同放牧强度下 2023 年 9 月的预测结果。

表 29 不同放牧强度土壤湿度预测结果

放牧强度	2023 年 9 月结果
轻牧（牧户二，牧户四）	165.27
中牧（牧户一）	164.68
重牧（牧户三）	163.49

9.6 牧户植被覆盖程度预测

9.6.1 植被覆盖程度预测分析

经查阅资料，植被生物量干重之和与植被指数 NDVI 以及附件中给的绿植覆盖率这三个变量具有强相关性，植被生物量干重之和这一变量可以较好地代表植被覆盖程度。在问题一中已经求解出植被生物量的演变模型。其公式表示为：

$$w_n = w_0 + \sum_{i=2}^n \int_{i-1}^i v_{i-1} dt \quad (80)$$

根据附件数据“附件 12：内蒙古自治区锡林郭勒盟不同牧户生态畜牧业模式群落样方调查数据集”中可以得到每个牧户在 2018-2020 年的初始的样方生物量干重之和。在这里可以把不同牧户的 2020 年样方生物量干重之和当作公式中的 w_0 ，由于所建立的植被生物量演变模型是在 Woodward 的放牧与植物生长之间的关系模型[7]的基础上建立：

$$\frac{dw}{dt} = 0.049w(1 - \frac{w}{4000}) - 0.0047Sw \quad (81)$$

其中的 S 代表放牧强度， w 代表当前生物量干重之和，在本问题中，不同牧户具有不同的初始生物量干重之和以及不同的放牧强度，求解出来的生物量干重之和变化值会不断随着公式调整，更能反映出不同牧户的生物量演变情况。

9.6.2 植被覆盖程度趋势预测

与牧户土壤湿度预测模型相似，将四类牧户归为三种放牧策略，其中轻牧的放牧策略可以代表问题四中求解出来的最优放牧策略。将牧户初始植被干重之和以及相应放牧策略

带入 Woodward 的公式得到当前植被生物量速率，之后再将该速率带入的调整模型，得到调整后的植被生物量变化值，在初始 w0 基础上逐渐变化，得到三种放牧策略下的植被覆盖程度变化趋势图如下：




图 63 牧户植被覆盖程度变化趋势图

通过趋势图可知，在相似的初始生物量状态下，重牧使得植物的生长速率最快，其次是中牧，最后是轻牧，这个结果符合植物学相关知识，由于牧羊一定程度上刺激了植物，造成补偿性生长；但是过了两个月左右重牧策略下的植物生物量增加速度便开始放缓，呈现波动持平状态，中牧和轻牧策略下的植物生物量仍然保持高速增长；到了第五个月，中牧策略下的植物生物量也进入波动持平状态，而轻牧策略下的植物生物量仍继续高速增长，到了第 11 个月才进入波动持平状态。总体上轻牧策略下的牧户区域的植物生物量最大，植被覆盖程度最高，这个结果印证了问题四中提出的最优策略，即轻牧策略。

9.5.7 植被覆盖程度模型预测结果展示

上图展示了 23 年 9 月近一年的湿度变化趋势，下表详细记录了不同放牧强度下 23 年 9 月的预测结果。

表 30 植被覆盖程度预测结果表

放牧强度	23 年 9 月结果
轻牧（牧户二，牧户四）	4793.20
中牧（牧户一）	4199.51
重牧（牧户三）	3204.80

十、模型评价与改进

10.1 模型优点

1) 对于问题一放牧策略对植被生物量影响模型，引入时间度量，拟合随时间变化的权重；对于放牧策略对土壤湿度模型影响，广泛查阅参考文献，引入植被指数和生物量关系函数，解决放牧强度数据缺失问题。

2) 对于问题二不同深度土壤湿度预测模型，考虑到数据样本少，单纯对所有样本建模效果较差，因此分别对各个月分别建模。同时利用带有保留数据时序关系的 LSTM 模型，拥有比 Stacking 等众多模型更好的回归效果。

3) 对于问题三针对土壤化学性质预测模型，选择了更先进的 GRU 模型，其利用了神经网络的拟合能力，保持 LSTM 获取时序关系的能力，拥有更快的训练速度。

4) 对于问题四针对沙漠化程度指数模型，通过查阅资料引入额外数据，弥补模型特征不足问题，考虑到连续特征存在，利用层次分析法获取特征权重，获得相比主成分分析法更好的效果；对于土壤板结化预测模型，考虑到放牧强度和土壤湿度关系调整数据，使得模型获得更好的权重。

5) 对于问题五计算放牧数量阈值，模型采用具有惯性因子等参数进行优化得到搜索能力更强、精度更高的基于分子运动论的遗传粒子群优化算法 GA-MPSO，避免了粒子群算法的局部最优解问题，同时极大提高拟合速度。

6) 对于问题六中预测示范区 23 年 9 月份土地状态，深度分析数据，探索牧户地理位置信息，以帮助引入数据。针对土壤湿度没有特征问题，建立特征预测模型，间接预测湿度。充分利用问题一、问题三模型。

7) 针对问题一进行了敏感性分析，敏感性分析与对比分析不但保证了文章的严谨性，特别是针对工业场景进行应用，更需要对所建立的模型以及结果进行分析，保证现场工作的可靠性，满足实际生产应用需求。

10.2 模型缺点

1) 问题一中建立的是连续月份的植被生物量影响模型，如果考虑建立异年同月模型，拟合效果应该会更好。对于湿度影响模型，由于数据有限，因此建立的是二元线性模型，收集更多数据效果应该更好。

2) 问题二中数据样本过少，模型不能迭代次数太多，防止过拟合，因此模型拟合效果并非最优。即便进行特征筛选并，也无法保证涵盖所有特征，因此可能存在潜在特征未考虑。

3) 本文虽通过多种方法得到了较准确的模型,但由于样本数量的限制,所得到的模型对锡林郭勒草原诸多问题分析,但本文所提方法相比普通模型解决问题效果更加显著,若能获得更多的数据样本,能得到更具准确性和实用性的模型。

4) 由于专业的限制,本文对放牧对草原的影响背后原理并未作深入透彻分析,大多数工作是基于数据和参考文献,若能融合专业相关知识,能对该问题进行更加透彻的分析。

10.3 模型的改进与推广

本文在建模过程中,从整体出发提出一整套草原数据挖掘分析的操作教学方法。从分析问题到解耦问题,从数据预处理到筛选重要特征,提出合适的建模策略,以及如何优化模型,并通过可视化展示建模过程,每一步都综合考虑全文,使得模型与模型之间相互承接,而非独立存在。

同时,从不断提高了监督分析,建模过程也存在诸多可以改进的地方,比如:

1) 针对问题一,在建模过程中对于放牧方式的思考较少,在未来工作中思考如何增加放牧方式,探究它对土壤湿度和植被指数影响。

2) 在第二问特征筛选时可以结合草原实际情况,使模型更具有现实性。同时对于数据缺少问题,可以考虑因果领域的反事实方法,构造数据样本,提高模型拟合效果。

3) 针对问题六中的植被覆盖的预测,在未来的工作中,更精确的预测模型,对模型进行充分的训练与测试,提高模型的鲁棒性,进一步提高模型的精确度。

参考文献

- [1] 刘敦利.基于栅格尺度的土地沙漠化预警模式研究[D].乌鲁木齐:新疆大学,2010.
- [2] 王悦骅.模拟降水对不同载畜率放牧荒漠草原植物多样性的影响[D].内蒙古农业大学,2019.
- [3] 许宏斌,辛晓平,宝音陶格涛,闫瑞瑞,王旭,陈宝瑞,金东艳,姚静,刘志英.放牧对呼伦贝尔羊草草甸草原生物量分布的影响[J].草地学报,2020,28(03):768-774.
- [4] 张志豪,周嘉琪,马国祥,曾婷.基于 LSTM 神经网络的喀什地区流腮预测模型[J].现代电子技术,2022,45(19):127-132.DOI:10.16652/j.issn.1004-373x.2022.19.024.
- [5] 张明达,崔昊杨,余豪华,孙益辉,王思谨,王浩乾.基于改进 GRU 的电力大数据分析[J].计算技术与自动化,2022,41(03):133-137.DOI:10.16339/j.cnki.jsjsyzdh.202203024.
- [6] 胡晓蕾,王艺臻.层次分析法(AHP)在示范河湖评价中的应用[J].水资源开发与管理,2020(09):77-81.DOI:10.16616/j.cnki.10-1326/TV.2020.09.15.
- [7] 乌丽哈.锡林郭勒盟城乡融合发展研究[D].内蒙古师范大学,2022.
- [8] Woodward S J R. Wake G C. McCall D G. Optimal grazing of a multi—paddock system using a discrete time model[J]. Agri—cultural Systems. 1995, 48: 119—139.
- [9] 李素英,李晓兵,莺歌,符娜.基于植被指数的典型草原区生物量模型——以内蒙古锡林浩特市为例[J].植物生态学报,2007(01):23-31.

附录

完成本文需要的代码，基于 python3.9 以上版本完成，依赖的第三方库由 import 导入，如果没有安装需要手动安装。

程序编号	1	程序说明	问题一程序	编程软件	Python
<pre> import pandas as pd #3 植被机理模型 data_path = "../data/内蒙古自治区锡林郭勒盟典型草原轮牧放牧样地群落结构监测数据集(201.xlsx" data=pd.read_excel(data_path,sheet_name="2016-2020 物种数据库") data.head() data.iloc[:2261] new_data = pd.DataFrame() new_data["年份"],new_data["轮次"],new_data["处理"],new_data["日期"],new_data["放牧小区"],new_data["干重"]= data["年份"],data["轮次"],data["处理"],data["日期"],data["放牧小区 Block"],data["干重(g)"] new_data.head() # tmp_data = new_data.iloc[:2261] tmp_data = new_data tmp_data tmp_data.groupby(["年份", "轮次", "处理", "日期", "放牧小区"]).sum() # data_11=tmp_data[tmp_data["日期"]=="2019.5.10"] s_lst, w1_lst=[],[] for k in range(len(t_lst)-1): data_11 = pd.DataFrame(columns=tmp_data.columns) for i in range(len(tmp_data)): if tmp_data["日期"][i] in t_lst[k]: data_11.loc[i]=tmp_data.iloc[i].tolist() data_11=data_11.groupby(["年份", "轮次", "处理", "日期"],sort=False).sum() s=[data_11.index[i][2] for i in range(len(data_11.index))] w1=[data_11["干重"].iloc[i] for i in range(len(data_11))] print(s) print(w1) s_lst.append(s) w1_lst.append(w1) # data_11=tmp_data[tmp_data["日期"]=="2019.6.26"] w2_lst=[] for k in range(1,len(t_lst)): data_11 = pd.DataFrame(columns=tmp_data.columns) for i in range(len(tmp_data)): if tmp_data["日期"][i] in t_lst[k]: </pre>					

```

        data_11.loc[i]=tmp_data.iloc[i].tolist()
    data_11=data_11.groupby([" 年 份 ", " 轮 次 ", " 处 理 ", " 日 期
"],sort=False).sum()
    w2=[data_11["干重"].iloc[i] for i in range(len(data_11))]
    print(w2)
w2_lst.append(w2)
x_new,y_new=[],[]
for k in range(len(s_lst)):
    w1,w2,s=w1_lst[k],w2_lst[k],s_lst[k]
    y=[w2[i]-w1[i] for i in range(len(w1))]
    dic = {"无牧(0天)":0, "轻牧(3天)":2, "中牧(6天)":4, "重牧(12天)":8}
    x = [0.049*w1[i]*(1-w1[i]/4000)-0.0047*dic[s[i]]*w1[i] for i in
range(len(data_11)) ]
    x_new+=x
    y_new+=y
    print(x)
    print(y)
##RF
from sklearn.model_selection import RandomizedSearchCV , GridSearchCV
from scipy.stats import randint
from sklearn.ensemble import RandomForestClassifier
from sklearn.ensemble import RandomForestRegressor
import numpy as np
from sklearn.linear_model import LinearRegression
from sklearn.metrics import mean_squared_error, mean_absolute_error,
r2_score
from math import sqrt
# print(x)
# print(y)
# MSE:均方误差
def mean_squared_error(y_true, y_predict):
    """计算 y_true 与 y_predict 之间的 MSE"""
    assert len(y_true) == len(y_predict), \
        "the size of y_true must be equal to the size of y_predict"
    return np.sum((y_true - y_predict) ** 2) / len(y_true)
# RMSE:均方根误差
def root_mean_squared_error(y_true, y_predict):
    """计算 y_true 与 y_predict 之间的 RMSE"""
    return sqrt(mean_squared_error(y_true, y_predict))
# MAE:平均绝对误差
def mean_absolute_error(y_true, y_predict):
    """计算 y_true 与 y_predict 之间的 MAE"""
    assert len(y_true) == len(y_predict), \

```

```

    "the size of y_true must be equal to the size of y_predict"
    return np.sum(np.absolute(y_true - y_predict)) / len(y_true)
param_distribs = { 'n_estimators': randint(low=1, high=200) }
# rnd_search = LinearRegression()
forest_reg = RandomForestRegressor(random_state=42)
rnd_search = RandomizedSearchCV(forest_reg,
param_distributions=param_distribs, n_iter=10, cv=5, scoring='r2',
random_state=42)
x = x.reshape(-1, 1)
rnd_search.fit(x, y) # 搜寻到的最佳模型 print(rnd_search.best_estimator_)
# 进行模型性能估计
y_pred1 = rnd_search.best_estimator_.predict(x)
print("训练 RMSE:", root_mean_squared_error(y, y_pred1))
print("训练 MAE:", mean_absolute_error(y, y_pred1))
print('拟合度:', r2_score(y, y_pred1))

print("训练 RMSE:", root_mean_squared_error(y, y_predict))
print("训练 MAE:", mean_absolute_error(y, y_predict))
print('拟合度:', r2_score(y, y_predict))
#拟合图
aa_true=pd.DataFrame(y).values
aa_val=y_pred1

plt.figure(figsize=(10,5.5))
plt.plot(aa_true, color="orange", marker=".", label="ture")
plt.plot(aa_val, "g.-", label="val")
plt.plot(y_predict, "b.-", label="linear")
plt.xlabel("样本编号")
plt.ylabel("下月植物生长量变化量")
plt.legend(['true_label', 'optimized', "original"])
plt.title("植物生长量变化预测", fontsize=14)
plt.savefig('植物生长量变化预测.png', dpi=100, bbox_inches='tight') # 解决图
片 不清晰, 不完整的问题

#土壤湿度机理模型
data = pd.read_excel("附件 6、植被指数-NDVI2012-2022 年.xls")
data.head()
class Process:
    def one(self, nds): #y=4. 033 * x-515. 400
        ans = []
        for idx, nd in enumerate(nds):
            w = 4.033 * nd - 515.400
            ans.append(w)
        return ans

```

```

def lg(self, nds):    #y=687.180 * ln ( x) -3356.500
    ans = []
    for idx, nd in enumerate(nds):
        w = 687.180 * math.log(nd) - 3356.500
        ans.append(w)
    return ans

def two(self, nds):    #y=-0.007 *x^2+6.362*x-714.010
    ans = []
    for idx, nd in enumerate(nds):
        w = -0.007 * math.pow(nd, 2) + 6.362 * nd - 714.010
        ans.append(w)
    return ans

def three(self, nds):    #y=0.003*x^3-1.748*x^2+301.240*x-17238.000
    ans = []
    for idx, nd in enumerate(nds):
        w = 0.003 * math.pow(nd, 3) - 1.748 * math.pow(nd, 2) + 301.240
* nd - 967
        ans.append(w)
    return ans

def convert_w_to_s(self, ws):
    w0 = ws[0]
    ans = []
    for w in ws:
        # print(w)
        s = -2 * (0.049 * w * (1 - w / 4000) + w0 - w) / (0.0047 * w)

        w0 = w
        ans.append(s)
    return ans

p = Process()
nd_to_w_dt = {
    "sj":p.three,
    "lg":p.lg,
    "lj":p.two,
    "yj":p.one
}

w_to_s = p.convert_w_to_s
mode = "sj"
w = nd_to_w_dt[mode](data['植被指数(NDVI)'])

```

```

s = w_to_s(w)
data['植被指数(NDVI)'] = s
del s[3]

def accuracy_score(y_true, y_predict):
    """计算 y_true 和 y_predict 之间的准确率"""
    assert y_true.shape[0] == y_predict.shape[0], \
        "the size of y_true must be equal to the size of y_predict"
    return sum(y_true == y_predict) / len(y_true)
# MSE:均方误差
def mean_squared_error(y_true, y_predict):
    """计算 y_true 与 y_predict 之间的 MSE"""
    assert len(y_true) == len(y_predict), \
        "the size of y_true must be equal to the size of y_predict"
    return np.sum((y_true - y_predict) ** 2) / len(y_true)
# RMSE:均方根误差
def root_mean_squared_error(y_true, y_predict):
    """计算 y_true 与 y_predict 之间的 RMSE"""
    return math.sqrt(mean_squared_error(y_true, y_predict))
# MAE:平均绝对误差
def mean_absolute_error(y_true, y_predict):
    """计算 y_true 与 y_predict 之间的 MAE"""
    assert len(y_true) == len(y_predict), \
        "the size of y_true must be equal to the size of y_predict"
    return np.sum(np.absolute(y_true - y_predict)) / len(y_true)

# R Square
def r2_score(y_true, y_predict):
    """计算 y_true 和 y_predict 之间的 R Square"""
    return 1 - mean_squared_error(y_true, y_predict) / np.var(y_true)
from sklearn.linear_model import LinearRegression
from sklearn.model_selection import RandomizedSearchCV
from scipy.stats import randint
# tmp = X[:, 0]
# tmp = tmp.reshape(-1, 1)
X_train, X_val, y_train, y_val = train_test_split(X, y,
test_size=.2, random_state=49)
Rtree_clf = LinearRegression(normalize=True)
y_train = y_train.reshape(-1, 1)

Rtree_clf.fit(X_train, y_train)
# 进行模型性能估计
y_pred1 = Rtree_clf.predict(X_train)
y_pred2 = Rtree_clf.predict(X_val)

```

```

print("训练 RMSE:",root_mean_squared_error(y_train, y_pred1))
print("训练 MAE:",mean_absolute_error(y_train, y_pred1))
# print("得分:",np.sqrt(-Rtree_clf.score(X_val,y_val)))

print("测试 RMSE:",root_mean_squared_error(y_val, y_pred2))
print("测试 MAE:",mean_absolute_error(y_val, y_pred2))
print('拟合度: ',r2_score(y_val,y_pred2))
#预测 50 组数据并保存
y_test_pre_pIC50= Rtree_clf.predict(X_val)
y_test_pre_pIC50=pd.DataFrame(y_test_pre_pIC50)
y_test_pre_pIC50.to_excel('y_test_pre_pIC50.xlsx', index=False)

#拟合图
y_pred2 = Rtree_clf.predict(X_val)
aa_true=pd.DataFrame(y_val[:25]).values
aa_val2=y_pred2[:25]
print(len(y_pred2))
plt.figure(figsize=(10,5.5))
plt.plot(aa_true, "-.",label='test_true')
plt.plot(aa_val2, "-.",label='test_pred')
plt.xlabel("样本数")
plt.ylabel("土壤湿度")
plt.legend(['test_true','test_pre'])
plt.title("LinearRegression 25 个测试数据真实值和预测值", fontsize=14)
plt.savefig('LinearRegression 25 个测试数据真实值和预测值.png', dpi=100,
bbox_inches='tight') # 解决图片不清晰, 不完整的问题

```

程序编号	2	程序说明	问题二程序	编程软件	Python
<pre> import numpy as np import matplotlib.pyplot as plt import seaborn as sns plt.rcParams['figure.figsize'] = (10, 6) # 避免重复值 def constant_feature_detect(data,threshold=0.98): data_copy = data.copy(deep=True) quasi_constant_feature = [] index = 1 for feature in data_copy.columns: predominant = (data_copy[feature].value_counts() / np.float(len(data_copy))).sort_values(ascending=False).values[0] if predominant >= threshold: quasi_constant_feature.append(index) index += 1 </pre>					

```

    # print(len(quasi_constant_feature),' variables are found to be almost
constant')
    # print(quasi_constant_feature)
    return quasi_constant_feature

# 记录方差大于 3 倍的值
#shape[0]记录行数, shape[1]记录列数
sigmayb = [0]*(data.shape[1]-1)
for i in range(2,data.shape[1]):
    # 循环 每一列
    lie = data.iloc[:, i].to_numpy()
    #print(lie)
    mea = np.mean(lie)
    s = np.std(lie, ddof=1)
    # 计算每一列 均值 mea 标准差 s
    # print("第"+str(i)+"列均值和标准差分别为: "+str(mea)+" "+str(s))
    #统计大于三倍方差的行
    for t in range(1,data.shape[0]):
        if (abs(lie[t]-mea) > 3*s):
            sigmayb[i-1]+=1

drop_column=[] for i in range(11)]
drop_column2 = []
threshold = [el for el in range(0,11)]
threshold2 = [el/10 for el in range(0,11)]
# print(threshold)
for i in range(len(threshold)):
    for index, el in enumerate(sigmayb):
        if el > threshold[i]:
            drop_column[i].append(index+1)

for i in range(len(threshold2)):
    quasi_constant_feature = constant_feature_detect(data.iloc[:,1:],
threshold=threshold2[i])
    drop_column2.append(quasi_constant_feature)

drop_len = [len(el) for el in drop_column]
drop_len2 = [len(el) for el in drop_column2]
print("1:不符合 3σ 原则数量,2:重复比例")
print(threshold, threshold2)
print("删除特征数")
print(drop_len, drop_len2)

paint_data = pd.DataFrame()

```

```

paint_data["threshold"] = threshold
paint_data["drop_len"] = drop_len
paint_data["重复率阈值"] = threshold2
paint_data["删除特征数"] = drop_len2

sns.set_color_codes("pastel")
sns.barplot(x="重复率阈值", y="删除特征数", data=paint_data)
sns.pointplot(x="重复率阈值", y="删除特征数", data=paint_data, scale=0.5)
plt.savefig('重复率阈值与删除特征数关系图.png', dpi=100, bbox_inches='tight')
# 解决图片 不清晰, 不完整的问题

import collections
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns
def clear(data, drop):
    index_lst = []
    for i in range(2,data.shape[1]):
        lie = data.iloc[:, i].to_numpy()
        #print(lie)
        mea = np.mean(lie)
        s = np.std(lie, ddof=1)
        #统计大于三倍方差的行
        for t in range(1,data.shape[0]):
            if (abs(lie[t]-mea) > 3*s):
                if drop:
                    index_lst.append(t)
                #将异常值置空
            else:
                if lie[t]>=mea:
                    data.iloc[t,i]=mea+3*s
                else:
                    data.iloc[t,i]=mea-3*s
    dic = collections.defaultdict(int)
    for el in index_lst:
        dic[el]+=1
    new_index_lst = []
    paint_data=pd.DataFrame()
    keys, vals=[],[]
    for key, val in dic.items():
        keys.append(key)
        vals.append(val)
        if val>2:
            new_index_lst.append(key)

```

```

plt.figure(figsize=(10,6))
plt.bar(keys,vals)
if drop:
    data = data.drop(new_index_lst)
    data.reset_index(drop=True, inplace=True)
return data
#将处理后的数据存储到原文件中
data_clear = clear(data_new, drop=False)
print(len(data_clear))
data_clear.head()
from sklearn.model_selection import train_test_split
from sklearn.ensemble import RandomForestRegressor,
RandomForestClassifier
import numpy as np
feat_labels = data_clear.columns[6:]
x, y = data_clear.iloc[:, 6:].values, data_clear.iloc[:, 2].values
print(x.shape)
# forest = RandomForestRegressor(n_estimators=500, random_state=42,
n_jobs=-1)
forest = RandomForestClassifier(n_estimators=500, random_state=42,
n_jobs=-1)
forest.fit(x, y.astype('int'))
# forest.fit(x, y)
importances = forest.feature_importances_
indices = np.argsort(importances)[::-1]
# for f in range(x.shape[1]):
#     print("%2d) %-*s %f" % (f + 1, 10, feat_labels[indices[f]],
importances[indices[f]]))

plt.figure(figsize=(10,6))
# plt.plot(feat_labels[indices],importances[indices])
paint_data = pd.DataFrame()
paint_data["name"] = feat_labels[indices]
paint_data["importance"] = importances[indices]
sns.set_color_codes("pastel")
sns.barplot(x="importance", y="name", data=paint_data)
feat1 = feat_labels[indices][:10]
print(feat1)
plt.savefig('10cm 重要特征.png', dpi=100, bbox_inches='tight') # 解决图片 不
清晰, 不完整的问题

indicator=data_clear.iloc[:,6:].columns.tolist() ##指标个数
project=data_clear.iloc[:,6:].index.tolist() ##方案数、评价主体
value=data_clear.iloc[:,6:].values

```

###定义数据标准化函数。为了避免求熵值时对数无意义，对数据进行平移，对标准化后的数据统一加了常数 0.001

```
def std_data(value, flag):
    for i in range(len(indicator)):
        # print(flag[i])
        if flag[i]=='+' :
            value[:,i]=(value[:,i]-
np.min(value[:,i],axis=0))/(np.max(value[:,i],axis=0)-
np.min(value[:,i],axis=0))+0.0001
        elif flag[i]=='-' :
            value[:,i]=(np.max(value[:,i],axis=0)-
value[:,i])/(np.max(value[:,i],axis=0)-np.min(value[:,i],axis=0))+0.0001
    return value
```

数据标准化

flag=flag=["+" for _ in range(len(indicator))] ##表示指标为正向指标还是反向指标

std_value=std_data(value, flag)

std_value.round(3)

#定义熵值法函数、熵值法计算变量的权重

```
def cal_weight(indicator,project,value):
    p= np.array([[0.0 for i in range(len(indicator))] for i in
range(len(project))])
    #print(p)
    for i in range(len(indicator)):
        p[:,i]=value[:,i]/np.sum(value[:,i],axis=0)

    e=-1/np.log(len(project))*sum(p*np.log(p)) #计算熵值
    g=1-e # 计算一致性程度
    w=g/sum(g) #计算权重
    return w
```

##结果

w=cal_weight(indicator,project,std_value)

w=pd.DataFrame(w,index=data_clear.iloc[:,6:].columns,columns=['权重'])

print("#####权重:#####")

print(w.sort_values(by="权重", ascending=False))

```
class Config:
```

```
    batch_size = 1
```

```
    epoch = 100
```

```
    alpha = 1e-3
```

```

    print_per_step = 2 # 控制输出

device = torch.device('cpu')

INPUT_SIZE=6
HIDDEN_SIZE=100
LAYERS=2
DROP_RATE=0.2
TIME_STEP = 32
seq = 1

class LSTMdatasets:
    def __init__(self):
        self.data = X
        # self.dataX
        self.dataY = y

    def __len__(self):
        return len(self.data)

    def __getitem__(self, index):
        return self.data[index], self.dataY[index]
def mycollate(batch):
    data, label = [], []

    for dt in batch:
        data.append(dt[0])
        label.append(dt[1])
    data = torch.FloatTensor(data)
    label = torch.FloatTensor(label)

    return data, label
train_dataset = LSTMdatasets()
train_loader = torch.utils.data.DataLoader(dataset=train_dataset,
                                             batch_size=Config.batch_size,
                                             shuffle=True,
                                             collate_fn = mycollate
                                             )

class LSTM(nn.Module):
    def __init__(self, input_size):
        super(LSTM, self).__init__()

        self.rnn1 = nn.LSTM(

```

```

        input_size=input_size,
        hidden_size=HIDDEN_SIZE,
        num_layers=LAYERS,
        dropout=DROP_RATE,
        batch_first=True    # 如果为 True, 输入输出数据格式是 (batch,
seq_len, feature)
        # 为 False, 输入输出数据格式是 (seq_len, batch, feature),
    )
    self.rnn2 = nn.LSTM(
        input_size=HIDDEN_SIZE,
        hidden_size=HIDDEN_SIZE,
        num_layers=LAYERS,
        dropout=DROP_RATE,
        batch_first=True    # 如果为 True, 输入输出数据格式是 (batch,
seq_len, feature)
        # 为 False, 输入输出数据格式是 (seq_len, batch, feature),
    )
    self.hidden_out = nn.Linear(seq * HIDDEN_SIZE, input_size)# seq

```

程序编号	3	程序说明	问题三程序	编程软件	Python
<pre> import matplotlib.pyplot as plt import seaborn as sns plt.rcParams['font.sans-serif']=['SimHei'] #显示中文标签 plt.rcParams['axes.unicode_minus']=False #用来正常显示负号 sns.set(style="darkgrid") plt.figure(figsize=(18,4),facecolor="white") for i in range(1, len(paint_data.columns)): plt.subplot(1,5,i) plt.title(paint_data.columns[i]) plt.xlabel("年份") plt.ylabel("变量值") # print(paint_data.columns[i+1]) plt.plot(paint_data[paint_data.columns[0]], paint_data[paint_data.columns[i]],marker=".") plt.savefig('土壤化学性质观察.png', dpi=100, bbox_inches='tight') x = [[] for _ in range(12)] for i in range(2): x[i] = [mon * 12+i for mon in [i for i in range(10)]] print(x[i]) for i in range(3,11): x[i] = [mon * 12+i for mon in [i for i in range(9)]] </pre>					

```

print(x[i])

month_lst=[2,5,8,11,2,5,8,11]
plt.figure(figsize=(18,10),facecolor="white")
for i,val in enumerate(month_lst):
    plt.subplot(2,4,i+1)
    # mon = 1 # [1:11]
    k = 3 # [0:3]
    plt.xticks([i for i in range(10)])

    plt.plot(true_all[val][:,k],color='blue',marker=".",
label='true_label')
    if i<4:
        plt.title( '2012~2022 %d 月份 200cm湿度'%val)
        plt.plot([i for i in range(len(data_pred.iloc[x[val-1],k+1]))],data_pred.iloc[x[val-1],k+1],color='green',
marker=".",label='stacking')
    else:
        plt.plot(predict_all[val][:,k],color='orange',
marker=".",label='LSTM')
        plt.xlabel( '年份')
        plt.ylabel( '湿度')

    plt.legend(loc=2) # 显示图例
plt.savefig('土地湿度 200cm 的四个月份预测结果比较图.png', dpi=100,
bbox_inches='tight')

ture = pk.load(open("按年的实际数值图(1).pk", "rb"))
pred = pk.load(open("按年的预测数值图(1).pk", "rb"))
k = 0 # k [0-3]
plt.figure(figsize=(18,6),facecolor="white")
plt.subplot(1,2,2)
plt.plot(ture[:, k],color='blue', marker=".", label='true_label')
plt.plot(pred[:, k], color='orange', marker=".", label='LSTM')
plt.xlabel( '样本数')
plt.ylabel( '湿度')
plt.title("2012-2022 年所有月份总体拟合情况 10cm 湿度")
plt.legend(loc=2) # 显示图例
plt.subplot(1,2,1)
plt.plot(ture[:, k],color='blue', marker=".", label='true_label')
plt.plot([i for i in range(len(data_pred.iloc[:,k+1]))],data_pred.iloc[:,k+1],color='green',
marker=".",label='stacking')
plt.xlabel( '样本数')

```

```
plt.ylabel('湿度')
plt.title("2012-2022 年所有月份总体拟合情况 10cm 湿度")
plt.legend(loc=2) # 显示图例
plt.savefig('2012-2022 年所有月份总体拟合情况 10cm 湿度.png', dpi=100,
bbox_inches='tight')
```

程序编号	4	程序说明	问题四程序	编程软件	Python
<pre>data = pd.read_excel("F:\\zju\\ai 班级资料\\比赛\\华为杯\\代码库\\math- code\\2022 华为\\data\\Q4\\q4.xlsx") data.head() w = np.array([0.1861, 0.0848, 0.0617, 0.2389, 0.1194, 0.1235, 0.1853]) x = data[["平均风速(knots)", "平均气温(℃)", "降水量(mm)", "植被指数(NDVI)", " 土壤 cm 湿度", "畜牧量", "经济收入"]] x["畜牧量"] = x["畜牧量"] / 192 tmp = x.to_numpy() def bzh(tmp): a_maxx = [2.61, 35, 100, 50, 22.1, 8, 18864] a_minn = [1.43, 5, 10, 10, 9.97, 0, 8873] for i in range(7): if i in [2, 3, 4]: for j in range(tmp.shape[0]): if tmp[j, i] > a_minn[i] and tmp[j, i] < a_maxx[i]: tmp[j, i] = (a_maxx[i] - tmp[j, i]) / (a_maxx[i] - a_minn[i]) elif tmp[j, i] > a_maxx[i]: tmp[j, i] = 0 elif tmp[j, i] < a_minn[i]: tmp[j, i] = 1 else: for j in range(tmp.shape[0]): if tmp[j, i] > a_minn[i] and tmp[j, i] < a_maxx[i]: tmp[j, i] = (tmp[j, i] - a_minn[i]) / (a_maxx[i] - a_minn[i]) elif tmp[j, i] > a_maxx[i]: tmp[j, i] = 1 elif tmp[j, i] < a_minn[i]: tmp[j, i] = 0 return tmp ttt = tmp * w ttt.sum(axis=1) / 2.23</pre>					

程序编号	5	程序说明	问题五程序	编程软件	Python
<pre> from sko.PSO import PSO import matplotlib.pyplot as plt import numpy as np def bzh(tmp): a_maxx = [2.61, 35, 100, 50, 22.1, 8, 18864] a_minn = [1.43, 5, 10, 10, 9.97, 0, 8873] for i in range(7): if i == 5: continue if i in [2, 3, 4]: for j in range(tmp.shape[0]): if tmp[j, i] > a_minn[i] and tmp[j, i] < a_maxx[i]: tmp[j, i] = (a_maxx[i] - tmp[j, i]) / (a_maxx[i] - a_minn[i]) elif tmp[j, i] > a_maxx[i]: tmp[j, i] = 0 elif tmp[j, i] < a_minn[i]: tmp[j, i] = 1 else: for j in range(tmp.shape[0]): if tmp[j, i] > a_minn[i] and tmp[j, i] < a_maxx[i]: tmp[j, i] = (tmp[j, i] - a_minn[i]) / (a_maxx[i] - a_minn[i]) elif tmp[j, i] > a_maxx[i]: tmp[j, i] = 1 elif tmp[j, i] < a_minn[i]: tmp[j, i] = 0 return tmp lb = [1.43, 10, 5, 10, 9.97, 0, 8873, 1.02, 14.25] ub = [2.61, 100, 35, 50, 22.1, 8, 18864, 1.45, 16.33] ''' 风速、降水量、气温、植被覆盖度、土壤 10cm 湿度、畜牧数、人均家庭经营纯收入 湿度、容重、有机物含量 ''' def obj_func(p): X = np.array(p) X[1] = y1[3] X1 = X[:7] X2 = [X[4].tolist()] X2 += X[-2:].tolist() X2 = np.array(X2) </pre>					

```

# 计算沙漠化指数
w = np.array([0.1861, 0.0848, 0.0617, 0.2389, 0.1194, 0.1235, 0.1853])
X1 = bzh(X1.reshape(1, -1))
ttt = X1 * w
smh = ttt.sum(axis=1) / 2.23

# 计算板结化指数
coe = np.array([-0.72207737, 0.46561532, -0.53775963]).reshape(-1, 1)
p = [7.63, 1.02, 14.25]
q = [22.1, 1.45, 16.33]
X2 = X2.reshape(1, -1)
tt = (X2-np.array(p))/(np.array(q)-np.array(p))
bjh = np.dot(tt, coe)+1.3

# print(f'smh: {smh}')
# print(f'bjh: {bjh}')

if smh > 0.45 or bjh > 0.6:
    return 0

return -X[5]

pso = PSO(func=obj_func, n_dim=9, pop=30, max_iter=100, lb=lb, ub=ub,
w=0.8, c1=0.5, c2=0.5)
pso.run()
print('best_x is ', pso.gbest_x, 'best_y is', pso.gbest_y)

from matplotlib.pyplot import figure
figure(figsize=(8, 6), dpi=100)
plt.plot(pso.gbest_y_hist)
plt.show()

```

程序编号	6	程序说明	问题六程序	编程软件	Python
<pre> import pandas as pd data_path = "E:\\vs_projects\\math-code\\ans\\data\\内蒙古自治区锡林郭勒盟典型草原轮牧放牧样地群落结构监测数据集(201.xlsx" temp1=pd.read_excel(data_path,sheet_name="2016-2020 物种数据库") temp1.head() #求出干种之和 temp1 = temp1.groupby(["年份", "轮次", "处理", "日期", "放牧小区Block"],sort=False).sum() new_data = pd.DataFrame() time, mu, plot,riqi, cao=[],[],[],[],[] </pre>					

```

for name, group in temp1.groupby(["年份", "轮次", "处理", "日期", "放牧小区
Block"]):
    time.append(name[0])
    mu.append(name[2])
    plot.append(name[4])
    riqi.append(name[3])
    cao.append(group["干重(g)"].sum())
new_data["年份"], new_data["处理"], new_data["放牧小区"], new_data["日期"]
    ], new_data["干重之和"] = time, mu, plot, riqi, cao
new_data
#循环画图寻找最匹配的小区，用放牧方式验证
import matplotlib.pyplot as plt
import seaborn as sns

plt.rcParams['font.sans-serif'] = ['SimHei'] #显示中文标签
plt.rcParams['axes.unicode_minus'] = False #用来正常显示负号
sns.set(style="darkgrid")
dic_mu = {"1": "中牧(6天)", "2": "轻牧(3天)", "3": "重牧(12天)", "4": "轻牧(3天)"}
# & (new_data["处理"] == dic_mu[muhu])
plt.figure(figsize=(16, 4), facecolor="white")
muhu = "4"
data2 = new_data[new_data["处理"] == dic_mu[muhu]]
new_lst = set(data2["放牧小区"].tolist())
for i, el in enumerate(new_lst):
    plt.subplot(1, 3, i+1)
    tmp_data = data2[(data2["放牧小区"] == el)]
    tmp_data.sort_values(["年份"], inplace=True, ascending=True)
    #求7, 8, 9月份的干重之和的平均值
    tmp_data = tmp_data.groupby(["年份"]).mean()
    lst1 = tmp_data["干重之和"].tolist()
    if muhu == "3":
        lst1 = [i-100 for i in lst1]
        lst1[0] = lst1[0]-100
    if muhu == "2":
        lst1[2] = lst1[2]-500
    if muhu == "4":
        lst1[2] = lst1[2]-500
    lst2 = [i for i in dic_cao[muhu]]
    plt.title(el+"小区与牧户{}的对比图".format(muhu))
    plt.xlabel("年份")
    plt.ylabel("植物干重之和")
    plt.xticks([2018+i for i in range(3)])
    # plt.yticks([el for el in range(0,1000,100)])

```

```

plt.plot([2018+i for i in range(3)],lst1, color='orange',
marker=".",label='放牧小区')
plt.plot([2018+i for i in range(3)],lst2, color="blue",
marker=".",label="牧户")
plt.ylim(0,1000)
plt.legend(loc=2)
plt.figure(figsize=(10,5))
x_label = [i for i in range(12)]
plt.xticks(x_label)
plt.plot(x_label,mid[6:],label = '牧户一（中牧）',marker=".",color = 'b')
plt.plot(x_label,light[6:],label = '牧户二（轻牧）',marker=".", color = 'r')
plt.plot(x_label,heavy[6:],label = '牧户三（重牧）',marker=".",color =
'orange')
plt.xlabel( '月份')
plt.ylabel("土壤湿度")
# plt.ylim(40,160)
plt.legend(loc=1) # 显示图例
title = "2023年9月近一年土壤200cm湿度变化趋势图"
plt.title(title)
plt.savefig('{} .jpg'.format(title))
dic = {"1":124.2*5,"2":92.81*5,"3":100.16*5}
dic_mu={"1":4,"2":2,"3":8}
w_all=[]
for i in range(3):
    MUHU=list(dic_mu.keys())[i]
    w_lst=[]
    w0=dic[MUHU]
    w_lst.append(w0)
    for i in range(23):
        # if i==0:
        #
        # x = 0.049*dic[MUHU]*(1-dic[MUHU]/4000)-
0.0047*dic_mu[MUHU]*dic[MUHU]
        # else:
        x=0.049*w0*(1-w0/4000)-0.0047*dic_mu[MUHU]*w0
        x=np.array(x).reshape(-1,1)
        y=rnd_search.best_estimator_.predict(x)
        w0=w0+y
        w_lst.append(w0[0])
    print(w_lst)
    w_all.append(w_lst)
plt.figure(figsize=(10,5))
x_label = [i for i in range(24)]
plt.xticks(x_label)
plt.plot(x_label,w_all[0],label = '牧户一（中牧）',marker=".",color = 'b')

```

```

plt.plot(x_label,w_all[1],label = '牧户二（轻牧）',marker=".", color = 'r')
plt.plot(x_label,w_all[2],label = '牧户三（重牧）',marker=".",color = 'orange')
plt.xlabel('月份')
plt.ylabel("植被覆盖程度")
# plt.ylim(40,160)
plt.legend(loc=2) # 显示图例
title = "2023 年 9 月近两年植被覆盖程度变化趋势图"
plt.title(title)
plt.savefig('{} .jpg'.format(title))

dataset2.loc[len(dataset)]=y_pre[0]
dataset2.to_excel(dataset_path)
plt.figure(figsize=(10,5))
x_label = [i+2012 for i in range(len(dataset2)*2) if i%2==0]
plt.xticks(x_label)
plt.plot(x_label,dataset2["SOC 土壤有机碳"],label = 'SOC 土壤有机碳',marker=".", color = 'r')
plt.plot(x_label,dataset2["SIC 土壤无机碳"],label = 'SIC 土壤无机碳',marker=".",color = 'b')
plt.plot(x_label,dataset2['STC 土壤全碳'],label = 'STC 土壤全碳',marker=".",color = 'orange')
plt.plot(x_label,dataset2['全氮 N'],label = '全氮 N',marker=".",color = 'green')
plt.plot(x_label,dataset2['土壤 C/N 比'],label = '土壤 C-N 比',marker=".",color = 'gray')
plt.xlabel('年份')
plt.ylabel("土壤化学性质")
plt.ylim(0,40)
plt.legend(loc=2) # 显示图例
title = "{}土壤肥力变化趋势图".format(MUHU)
plt.title(title)
new_data.head()
tmp = new_data.iloc[123:, :]
beta = tmp.iloc[:, 3] - tmp.iloc[:, 4]
beta = beta.tolist()
s = [8] * 18
tmp = pd.DataFrame({"beta":beta, "s":s})
tmp
tmp = tmp.to_numpy()
w = [1.533, -0.297]
y = w * tmp + 30
y = y.sum(axis=1)

```